

TRABAJO FIN DE MÁSTER
**Mejora de la predicción de
cotizaciones de activos de renta
variable mediante inteligencia
artificial**

Autor: Marc Delos Poch

Director: Dr. Wolfram Rozas Rodríguez

Fecha: Octubre 2025

MÁSTER FP en INTELIGENCIA ARTIFICIAL

Ve más allá

Introducción, Contexto/Motivación

- **Motivación:** Me **apasiona** la arquitectura del **software**, y en especial la de los sistemas de *algorithmic trading*, donde convergen la **ingeniería** y la automatización de **decisiones financieras**, en un marco **especulativo**.
- Los mercados financieros son **complejos, volátiles y difíciles de predecir**.
- El **80 %** de las operaciones se realizan mediante **trading algorítmico**.
- Los métodos tradicionales estadísticos y de machine learning presentan **limitaciones estructurales**.
- El **deep learning** ofrece una mejora ante estas limitaciones para detectar **patrones complejos** debido a su estructura no lineal y **temporales** debido a su capacidad de memoria
- Este trabajo **compara tres técnicas** deep learning sobre un ETF sintético, con el objetivo de mejorar la **predicción** y la **eficiencia** del trading automatizado, y así poder **maximizar rentabilidad** y **minimizar riesgos**.



Estado del arte

Modelos tradicionales
1970

**ARIMA, GARCH,
Regresión lineal,
Regresión logística**

- + Interpretables
- + Requiere pocos datos
- + Rápidos

- Asumen linealidad
- Asumen estacionalidad
- Poco rendimiento

Aprendizaje automático
1995

**SVM, Random Forrest,
XGBoost, ...**

- + relaciones no lineales
- + relaciones complejas
- + robustez ante ruido

- No memoria temporal
- Tienen overfitting
- Limitada Intepretab.

Redes neuronales Profundas
2015

**MLP, LSTM, N-BEATS,
Transformer ...**

- + Rendimiento
- + no lineales
- + tendencias temporales
- + no estacionarios

- Requiere muchos datos
- Hyperparámetros
- Peligro overfitting
- Poca interpretabilidad

Modelos híbridos
2020

**ARIMA+LSTM,
TSFEDL (CNN+RNN) ...**

- + Rendimiento
- + Aprovecha ventajas
- + Mejor generalización
- + Tend. corto+largo plazo

- Requiere muchos datos
- Mayor complejidad
- Hyperparámetros
- Peligro overfitting
- Poca interpretabilidad



Objetivos

Evaluar el rendimiento predictivo de tres modelos de inteligencia artificial en la estimación del retorno logarítmico de precios de un **ETF sintético del sector tecnológico**, utilizando datos horarios y métricas relevantes en un contexto de **trading algorítmico**.

- Crear un **ETF sintético** con 5 acciones tecnológicas (AAPL, MSFT, NVDA, IBM, GOOG) horarias (2021-2024)
- **Implementar tres modelos** Deep Learning del estado del arte: **LSTM**, **N-BEATS** y **TSFEDL** (CNN+RNN)
- **Evaluar resultados** mediante métricas de error, precisión direccional y rendimiento financiero
- Se buscó **determinar** qué arquitectura ofrece el **mejor equilibrio** entre precisión, rendimiento financiero, estabilidad y viabilidad para trading algorítmico



Metodología (CRISP-DM)

Business Understanding:

Predicción de retornos logarítmicos con un objetivo especulativo

Data Understanding:

Datos brutos de (AAPL, MSFT, NVDA, IBM, GOOG) horarios 2021-2024

Data Preparation:

ETF sintético / Limpieza / Normalización / Variables / Div.temporal / EDA

Modeling:

Métodos LSTM, N-BEATS y TSFEDL, entrenamiento y predicción

Evaluation:

Métricas de error, rendimiento, financieras y estabilidad.

Deployment: No se realizó (objetivo académico)

Datos en bruto:

- date + close + volume + log_return

Dataset ETF sintético:

- log_return
- log_volume
- close
- date_hour, date_day, date_month
- macd_histogram, macd, macd_signal
- volatility_24, obv
- sofr, vix (exógenas)

Variable objetivo:

- target_log_return (t+1)




Modelado

Modelos baseline: Zero, Random y Mean


LSTM

Red **recurrente** especializada en secuencias temporales de largo plazo.



N-BEATS


Arquitectura **no recurrente** basada en **bloques residuales**.



TSFEDL



Modelo **híbrido** CNN + RNN.

CNN: Extracción características
RNN: Predicción temporal





Resultados

		Métricas de error / rendimiento				Métricas financieras		Métricas computacionales		Estabilidad
		MSE	RMSE	MAE	R ²	Dirección	Sharpe ratio	T.Entreno (s)	T.Predicción (s)	ANOVA p-value
Modelos	LSTM	0.0000052	0.002282	0.001080	0.00127	60.65 %	0.026	155	≈ 3	0.042
	N-BEATS	0.0000056	0.002387	0.001188	-0.0927	67.47 %	0.054	37	≈18	0.825
	TSFEDL	0.0000052	0.002282	0.001095	0.00077	60.27 %	0.030	210	≈ 1	0.382



Ejemplo visual de predicción



Conclusiones

- Los modelos **capturaron parcialmente** la dinámica del mercado, reproduciendo la dirección general de los movimientos de precio.
- **N-BEATS** destacó por su mayor precisión direccional (67%) y Sharpe ratio (0.0054). **LSTM** mostró rendimiento a largo plazo pero no a corto, mientras que **TSFEDL** tuvo un comportamiento intermedio.
- La predicción exacta de retornos sigue siendo difícil debido a la **volatilidad** y **naturaleza estocástica** de los mercados.
- La inteligencia artificial aplicada a la predicción financiera es una **vía prometedora y viable**.





**Universidad
Europea**

Gracias

Preguntas

Marc Delos Poch

marcdp@dprojects.com

Ve más allá