



**Universidad
Europea**

UNIVERSIDAD EUROPEA DE MADRID

ESCUELA DE ARQUITECTURA, INGENIERÍA Y DISEÑO

MÁSTER EN FORMACION PERMANENTE EN INTELIGENCIA ARTIFICIAL

APLICADA

TRABAJO FIN DE MÁSTER

**Mejora de la predicción de cotizaciones de activos
de renta variable mediante inteligencia artificial**

MARC DELOS POCH

Dirigido por

Dr. WOLFRAM ROZAS RODRIGUEZ

CURSO 2024-2025

TÍTULO: Mejora de la predicción de cotizaciones de activos de renta variable mediante
inteligencia artificial

AUTOR: MARC DELOS POCH

TITULACIÓN: MÁSTER DE FORMACIÓN PERMANENTE EN INTELIGENCIA ARTIFICIAL APLICADA

DIRECTOR/ES DEL PROYECTO: Dr. WOLFRAM ROZAS RODRIGUEZ

FECHA: octubre de 2025

RESUMEN

El presente trabajo tiene como finalidad mejorar la predicción de cotizaciones de activos de renta variable, mediante redes neuronales profundas, con el objetivo de optimizar la toma de decisiones especulativas dentro de un sistema de trading algorítmico automatizado.

Con este propósito, se construyó un ETF sintético compuesto por cinco acciones tecnológicas reales utilizando datos horarios entre 2021 y 2024. A partir de estas series se generaron las variables de entrada y los retornos logarítmicos empleados como objetivo de predicción.

Sobre este conjunto de datos se desarrollaron y entrenaron tres modelos basados *deep learning*: una red LSTM orientada a capturar dependencias temporales, un modelo N-BEATS centrado en la descomposición de patrones residuales, y un modelo TSFEDL, de naturaleza híbrida, que combina capas convolucionales y recurrentes.

Los modelos se evaluaron mediante métricas de error, precisión direccional, y desempeño financiero, y se contrastaron con modelos *baseline* estadísticos y aleatorios.

Los resultados obtenidos demuestran que las tres arquitecturas son aptas para la predicción de retornos logarítmicos, superando a los modelos base. En particular, el modelo N-BEATS ofrece el mejor equilibrio entre precisión direccional y estabilidad, confirmando la viabilidad del uso de redes neuronales profundas como herramienta de apoyo en la especulación automatizada de mercados financieros.

Palabras clave:

Deep learning, series temporales, predicción de precios financieros, trading algorítmico, N-BEATS.

ABSTRACT

This work addresses the improvement of equity price forecasting through artificial intelligence techniques applied to high-frequency financial data.

For this purpose, a synthetic ETF was constructed by combining five real technology stocks with hourly data spanning from 2021 to 2024. From this dataset, a series of input variables and logarithmic returns were generated to serve as the prediction target.

Three deep learning architectures were developed and trained: an LSTM network designed to capture temporal dependencies, an N-BEATS model focused on residual pattern decomposition, and a TSFEDL hybrid model that integrates convolutional and recurrent components.

The models were evaluated and compared using various error, directional, and financial performance metrics, and were contrasted against several statistical and random baseline models.

The results demonstrate that all three architectures are suitable for log-return prediction, achieving a significant improvement over the baseline approaches. In particular, the N-BEATS model achieved the best balance between directional accuracy and stability, confirming the feasibility of applying deep neural networks to financial time series forecasting and highlighting their potential for integration into automated algorithmic trading systems.

Keywords:

Deep learning, time series, financial price forecasting, algorithmic trading, N-BEATS.

AGRADECIMIENTOS

A Mario, gracias por tu apoyo incondicional y tu paciencia en cada etapa de este camino.

TABLA RESUMEN

	DATOS
Nombre y apellidos:	Marc Delos Poch
Título del proyecto:	Mejora de la predicción de cotizaciones de activos de renta variable mediante inteligencia artificial
Directores del proyecto:	Dr. WOLFRAM ROZAS RODRIGUEZ
El proyecto se ha realizado en colaboración de una empresa o a petición de una empresa:	NO
El proyecto ha implementado un producto: (esta entrada se puede marcar junto a la siguiente)	NO
El proyecto ha consistido en el desarrollo de una investigación o innovación: (esta entrada se puede marcar junto a la anterior)	SI
Objetivo general del proyecto:	Mejora de la predicción de cotizaciones de activos de renta variable mediante inteligencia artificial y Trading Algorítmico

Índice

RESUMEN	3
ABSTRACT	4
AGRADECIMIENTOS.....	5
TABLA RESUMEN	6
INTRODUCCIÓN	13
Capítulo 1. RESUMEN DEL PROYECTO	15
1.1 Contexto y justificación.....	15
1.2 Planteamiento del problema	15
1.3 Objetivos del proyecto.....	15
1.4 Resultados obtenidos	15
1.5 Estructura de la memoria	15
Capítulo 2. ANTECEDENTES / ESTADO DEL ARTE	16
2.1 Estado del arte	16
2.2 Contexto y justificación.....	21
2.3 Planteamiento del problema	21
Capítulo 3. OBJETIVOS.....	22
3.1 Objetivos generales	22
3.2 Objetivos específicos	22
3.3 Beneficios del proyecto	23
Capítulo 4. DESARROLLO DEL PROYECTO	24
4.1 Planificación del proyecto.....	24
4.2 Descripción de la solución, metodologías y herramientas empleadas.....	24
4.3 Recursos requeridos	74
4.4 Presupuesto	75
4.5 Viabilidad	76
4.6 Resultados del proyecto	76

Capítulo 5.	DISCUSIÓN.....	78
Capítulo 6.	CONCLUSIONES.....	79
6.1	Conclusiones del trabajo.....	79
6.2	Conclusiones personales.....	79
Capítulo 7.	FUTURAS LÍNEAS DE TRABAJO	81
Capítulo 8.	REFERENCIAS.....	82
Capítulo 9.	APÉNDICES	85
9.1	Apéndice A. Formulas y definiciones matemáticas	85
9.2	Apéndice B. Uso de herramientas de asistencia en la redacción	88

Índice de Figuras

Ilustración 1. Evolución de los modelos para predicción financiera. Elaboración propia.	18
Ilustración 2. Planificación del proyecto. Elaboración propia.	24
Ilustración 3. Diagrama CRISP-DM [27].....	25
Ilustración 4. Outliers de los log_return del ETF. Elaboración propia.....	31
Ilustración 5. Precio reconstruido del ETF. Elaboración propia.	32
Ilustración 6. (a) Serie temporal de precio. (b) Serie temporal de log-returns. Elaboración propia.	38
Ilustración 7. Histograma de log-returns horarios. Elaboración propia.....	40
Ilustración 8. Histograma de precios de cierre. Elaboración propia.	40
Ilustración 9. Histograma de “volume”. Elaboración propia.....	40
Ilustración 10. Histograma de log_volume. Elaboración propia.	41
Ilustración 11. Histogramas de EMA10, EMA50 y EM200. Elaboración propia.	41
Ilustración 12. Histograma de ema_ratio. Elaboración propia.	41
Ilustración 13. Histograma de ema_spread. Elaboración propia.....	42
Ilustración 14. Histograma de macd. Elaboración propia.	42
Ilustración 15. Histograma de volatility24h. Elaboración propia.....	43
Ilustración 16. Histograma de obv. Elaboración propia.....	43
Ilustración 17. Histograma de vix. Elaboración propia.	43
Ilustración 18. Histograma de sofr. Elaboración propia.....	44
Ilustración 19. Particiones de entrenamiento, validación y prueba. Elaboración propia.....	44
Ilustración 20. Matriz de correlación entre las variables. Elaboración propia.....	46
Ilustración 21. Detalle de la relación entre log-returns y la volatilidad móvil de 24 horas. Elaboración propia.	47
Ilustración 22. Evolución del precio de cierre, el índice VIX y la tasa SOFR. Elaboración propia.	47
Ilustración 23. Distribución de los log-returns. Elaboración propia.....	48
Ilustración 24. Función de pérdida durante entrenamiento y validación para LSTM. Elaboración propia.	53
Ilustración 25. Función de pérdida durante entrenamiento y validación N-BEATS. Elaboración propia.	54

Ilustración 26. Función de pérdida durante entrenamiento y validación para TSFEDL. Elaboración propia.	55
Ilustración 27. Evolución de log-returns del modelo Distribution Random, para el conjunto de prueba. Elaboración propia.....	60
Ilustración 28. Evolución precios del modelo Distribution Random. Elaboración propia.	60
Ilustración 29. Evolución de log-returns del modelo Mean, para el conjunto de prueba. Elaboración propia.	61
Ilustración 30. Evolución precios del modelo Mean. Elaboración propia.....	62
Ilustración 31. Evolución de log-returns del modelo Zero, para el conjunto de prueba. Elaboración propia.	63
Ilustración 32. Evolución precios del modelo Zero. Elaboración propia.....	63
Ilustración 33. Evolución de precio y predicciones acumuladas de los modelos baseline. Elaboración propia.	64
Ilustración 34. Evolución de log-returns del modelo LSTM, para el conjunto de prueba. Elaboración propia.	66
Ilustración 35. Evolución precios del modelo LSTM. Elaboración propia.	66
Ilustración 36. Evolución de log-returns del modelo N-BEATS, para el conjunto de prueba. Elaboración propia.	67
Ilustración 37. Evolución de precios del modelo N-BEATS. Elaboración propia.	67
Ilustración 38. Evolución de log-returns del modelo TSFEDL, para el conjunto de prueba. Elaboración propia.	68
Ilustración 39. Evolución de precios del modelo TSFEDL. Elaboración propia.	68
Ilustración 40. Comparación entre los log-returns reales y las predicciones. Elaboración propia.	69
Ilustración 41. Evolución precios y predicciones acumuladas de los modelos. Elaboración propia.	70

Índice de Tablas

Tabla 1. Clasificación de modelos de predicción de series temporales. Elaboración propia.	18
Tabla 2. Estudio 1: Hybrid Models for Financial Forecasting: Combining Econometric, Machine Learning, and Deep Learning Models. Elaboración propia.	19
Tabla 3. Estudio 2: Combining multiple feature selection methods for stock prediction: Union, intersection, and multi-intersection approaches. Elaboración propia.	19
Tabla 4. Estudio 3: Stock Price Prediction Using Neural Network Models Based on Tweets Sentiment Scores. Elaboración propia.	20
Tabla 5. Estudio 4: Deep Learning for Financial Time Series Prediction. Elaboración propia.	20
Tabla 6. Activos seleccionados. Elaboración propia.	26
Tabla 7. Origen de datos de precios. Elaboración propia.	27
Tabla 8. Origen de datos de capitalizaciones de mercado. Elaboración propia.	27
Tabla 9. Origen de datos de variables macroeconómicas. Elaboración propia.	28
Tabla 10. Outliers en los activos. Elaboración propia.	30
Tabla 11. Resumen de variables. Elaboración propia.	35
Tabla 12. Estadísticos descriptivos de las variables. Elaboración propia.	36
Tabla 13. Outliers en el conjunto de datos final. Elaboración propia.	39
Tabla 14. Estadísticos de las EMAs.	41
Tabla 15. Estadísticos de macd. Elaboración propia.	42
Tabla 16. Estadísticos de los conjuntos de entrenamiento, validación y test. Elaboración propia.	47
Tabla 17. Métricas del modelo Distribution Random. Elaboración propia.	59
Tabla 18. Métricas del modelo Mean. Elaboración propia.	61
Tabla 19. Métricas del modelo Zero. Elaboración propia.	62
Tabla 20. Métricas de los modelos baseline. Elaboración propia.	64
Tabla 21. Métricas del modelo LSTM. Elaboración propia.	65
Tabla 22. Métricas del modelo N-BEATS. Elaboración propia.	66
Tabla 23. Métricas del modelo TSFEDL. Elaboración propia.	68
Tabla 24. Métricas de los modelos. Elaboración propia.	70
Tabla 25. Métricas de rendimiento computacional y complejidad. Elaboración propia.	71
Tabla 26. Métricas de estabilidad. Elaboración propia.	72

Tabla 27. Precio de los recursos requeridos. Elaboración propia. 75

Tabla 28. Presupuesto. Elaboración propia. 75

INTRODUCCIÓN

Predecir el comportamiento de los mercados financieros ha sido, desde siempre, uno de los grandes retos tanto para investigadores como para profesionales del sector. A medida que los mercados se han vuelto más complejos y volátiles, también ha aumentado la necesidad de herramientas que permitan anticipar sus movimientos de forma más precisa y eficiente. Esta capacidad predictiva es fundamental para tomar decisiones informadas, diseñar estrategias de inversión o especulación sólidas y minimizar riesgos en un entorno altamente competitivo y dinámico.

En la actualidad, una parte muy significativa del volumen de operaciones bursátiles es ejecutada por sistemas automatizados. Algunos estudios [1] indican que cerca del 80% de las transacciones en los principales mercados financieros se realizan mediante algoritmos. Este fenómeno, conocido como trading algorítmico, consiste en el uso de programas informáticos capaces de tomar decisiones de compra y venta de activos siguiendo un conjunto de reglas predefinidas, que pueden estar basadas en análisis técnico, señales estadísticas o modelos de inteligencia artificial. Su objetivo es aprovechar oportunidades de mercado de manera rápida, eficiente y sin intervención humana directa.

El auge del trading algorítmico ha impulsado la búsqueda de modelos predictivos cada vez más sofisticados, capaces de reaccionar en tiempo real a cambios en los datos y de anticipar movimientos futuros con la mayor precisión posible. En este contexto, los modelos de inteligencia artificial (y especialmente los de aprendizaje profundo) han ganado protagonismo como herramientas capaces de detectar patrones complejos, no lineales y difíciles de identificar mediante métodos tradicionales.

Este Trabajo de Fin de Máster se enmarca en esa tendencia, y tiene como objetivo principal analizar y comparar el rendimiento de tres modelos de aprendizaje profundo en la predicción de precios financieros: Long Short-Term Memory (LSTM), N-BEATS (Neural Basis Expansion Analysis for Time Series Forecasting) y TSFEDL (Time Series Spatio-Temporal Feature Extraction and Prediction using Deep Learning). Para ello, se construye un ETF sintético a partir de datos históricos horarios de cinco grandes empresas tecnológicas (Apple, Microsoft, NVIDIA, IBM y Google) y se evalúa el rendimiento de cada modelo sobre dicha serie, con especial atención a métricas relevantes en un contexto de especulación algorítmica, como la precisión direccional, la ratio de Sharpe y la estabilidad de las predicciones.

La elección de un ETF sintético responde a la intención de trabajar con un activo compuesto, diversificado y más representativo del comportamiento conjunto del sector tecnológico. Al no limitarse a una sola acción, este enfoque permite evaluar los modelos en un escenario más realista y cercano a los productos financieros utilizados en la práctica profesional, como fondos indexados o estrategias de inversión sectorial.

Además de implementar los modelos, el proyecto incluye la construcción de un pipeline completo de procesamiento, entrenamiento y evaluación, diseñado para manejar series temporales de alta frecuencia. Este sistema automatizado permite no solo reproducir los

experimentos de forma controlada, sino también analizar los resultados de manera rigurosa, comparando los modelos en igualdad de condiciones. Se abordan aspectos clave como la normalización de los datos, la creación de ventanas de entrada para alimentar las redes, la evaluación sobre conjuntos de validación y prueba, y la interpretación de los resultados obtenidos.

Una de las particularidades de este trabajo es que no solo se enfoca en medir la precisión numérica de los modelos (a través de métricas como el MAE, RMSE o R^2), sino que también incorpora métricas orientadas a su utilidad práctica en escenarios reales de inversión, como la capacidad de anticipar correctamente la dirección del mercado (precisión direccional), la eficiencia ajustada al riesgo (Sharpe ratio), y el rendimiento computacional. Esta perspectiva más orientada a la acción permite evaluar los modelos no solo desde su desempeño técnico, sino también desde su aplicabilidad en estrategias reales de trading automatizado.

La estructura de la memoria sigue el enfoque metodológico CRISP-DM, adaptado al contexto de ciencia de datos aplicada a finanzas. El documento comienza con una revisión del contexto y del estado del arte, donde se describen las distintas familias de modelos aplicadas históricamente a la predicción financiera, desde enfoques estadísticos hasta arquitecturas híbridas modernas. A continuación, se presenta el diseño metodológico, detallando tanto el proceso de construcción del ETF sintético como la implementación de los modelos seleccionados. Luego se exponen los resultados obtenidos y se realiza un análisis comparativo de su rendimiento. Finalmente, se recogen las conclusiones, reflexiones personales y propuestas para futuras líneas de investigación.

Con este proyecto se pretende aportar una visión práctica y rigurosa sobre el uso de modelos de *deep learning* en la predicción bursátil, y contribuir a una mejor comprensión de sus capacidades, limitaciones y potencial real en contextos de especulación algorítmica, que hoy en día representan una parte esencial del funcionamiento de los mercados financieros.

Capítulo 1. RESUMEN DEL PROYECTO

1.1 Contexto y justificación

Los mercados financieros son cada vez más volátiles, y anticipar el movimiento de los precios se ha vuelto esencial para diseñar estrategias de inversión eficaces. En los últimos años, ha crecido el interés por aplicar inteligencia artificial al análisis de datos históricos, con el objetivo de detectar patrones que permitan predecir el comportamiento del mercado.

1.2 Planteamiento del problema

En la predicción de precios de activos de renta variable mediante los métodos estadísticos tradicionales ofrecen resultados limitados, mientras que la inteligencia artificial permite detectar patrones más complejos. Entre los principales desafíos destacan el ruido y la heterogeneidad de los precios, la elección del modelo adecuado y la evaluación rigurosa de su rendimiento.

1.3 Objetivos del proyecto

Evaluar el rendimiento predictivo de tres modelos de inteligencia artificial en la estimación del retorno de precios de un ETF sintético, construido a partir de los datos horarios históricos de cinco acciones del sector tecnológico (Apple, Microsoft, NVIDIA, IBM y Google) durante un periodo de cuatro años.

1.4 Resultados obtenidos

El proyecto culminó con el desarrollo de un sistema completo de predicción de precios financieros basado en *deep learning*, capaz de procesar series temporales de alta frecuencia. Para ello, se construyó un ETF sintético, sobre el que se aplicaron tres modelos: LSTM, N-BEATS y TSFEDL. El sistema incluye un pipeline automatizado de preprocesamiento y evaluación. Se demostró que los modelos de *deep learning* superan claramente a los modelos base, destacando N-BEATS por su equilibrio entre precisión y estabilidad.

1.5 Estructura de la memoria

La memoria se estructura siguiendo la metodología CRISP-DM, abarcando todo el proceso de desarrollo del proyecto. Tras una introducción con el contexto, justificación y objetivos, se presenta una revisión del estado del arte sobre inteligencia artificial aplicada a las finanzas. Posteriormente, se describe la metodología y el diseño experimental, seguida del desarrollo técnico, que incluye la construcción del ETF sintético y la implementación de los modelos *baseline* y de *deep learning*. A continuación, se detallan los resultados y su evaluación comparativa, para finalmente exponer las conclusiones, las reflexiones personales y las líneas futuras de trabajo.

Capítulo 2. ANTECEDENTES / ESTADO DEL ARTE

La predicción del comportamiento del mercado bursátil ha sido un desafío central tanto en el ámbito académico como en la industria financiera. A lo largo de las últimas décadas, se han desarrollado numerosos enfoques para abordar esta tarea, desde modelos estadísticos tradicionales hasta sofisticadas arquitecturas de inteligencia artificial. Este capítulo presenta una revisión estructurada de las principales metodologías aplicadas a la predicción de precios financieros, analizando su evolución, fundamentos teóricos y resultados empíricos. Se abordan las cuatro grandes categorías de modelos utilizados en la literatura: modelos estadísticos clásicos, algoritmos de aprendizaje automático, redes neuronales profundas y enfoques híbridos. Esta revisión permite contextualizar y justificar la selección de modelos comparados en este trabajo, así como resaltar las tendencias actuales y las limitaciones que aún persisten en el campo.

2.1 Estado del arte

La predicción bursátil ha evolucionado desde modelos estadísticos clásicos hasta arquitecturas de inteligencia artificial, que buscan capturar la complejidad no lineal de los mercados.

Algunos de los trabajos revisados emplean el retorno logarítmico [2] como variable objetivo en lugar del precio absoluto. Esta elección, común en el análisis financiero, permite trabajar con cambios relativos en el precio de forma más estable. Además, ofrece ventajas estadísticas importantes, como la posibilidad de sumar retornos a lo largo del tiempo y una distribución más cercana a la normal, lo que facilita la aplicación de distintos modelos de predicción.

2.1.1 Modelos tradicionales

Modelos estadísticos como el Autoregressive Integrated Moving Average (ARIMA) [3] y el Generalized Autoregressive Conditional Heteroskedasticity (GARCH) [4] han sido ampliamente utilizados para modelar series temporales financieras, permitiendo estimar respectivamente la tendencia y la volatilidad de los precios. El primero combina componentes autorregresivos, de media móvil y de diferenciación, mientras que el segundo modela la variación temporal de la volatilidad, reflejando fenómenos como la “aglomeración de la volatilidad”.

Sin embargo, ambos dependen de la linealidad y estacionariedad de las series, condiciones que rara vez se cumplen en los mercados financieros, caracterizados por comportamientos no lineales, dinámicos y volátiles [5]. Estas limitaciones han impulsado el desarrollo de enfoques más avanzados, como el aprendizaje automático y las redes neuronales profundas, capaces de capturar relaciones más complejas y adaptarse mejor a la naturaleza cambiante del mercado.

2.1.2 Aprendizaje automático

En los últimos años, el aprendizaje automático ha revolucionado el análisis financiero, al introducir modelos capaces de capturar relaciones no lineales y complejas sin depender de la estacionalidad o linealidad de los datos. Entre los más utilizados destacan las Support Vector

Machines (SVM) [6], los Random Forest [7] y los métodos de Gradient Boosting (GBM, XGBoost, LightGBM) [8] [9] [10].

Los modelos basados en SVM se aplican tanto a la clasificación direccional como a la regresión de precios, ofreciendo robustez en entornos ruidosos. Los Random Forest combinan múltiples árboles de decisión para mejorar la precisión y reducir el sobreajuste, mientras que los modelos de *boosting* construyen árboles secuenciales que corrigen errores anteriores, logrando alta precisión y escalabilidad, especialmente en contextos de *trading* algorítmico y grandes volúmenes de datos [11].

Pese a su rendimiento superior, estos modelos presentan el reto de la baja interpretabilidad, lo que limita su adopción en entornos donde la transparencia es clave. Para mitigarlo, se emplean técnicas explicativas como SHAP y LIME, aunque alcanzar un equilibrio entre precisión y explicabilidad sigue siendo uno de los principales desafíos de la inteligencia artificial aplicada a las finanzas [12].

2.1.3 Redes neuronales profundas

Las redes neuronales profundas se han consolidado como una herramienta clave en la predicción financiera gracias a su capacidad para detectar patrones complejos y relaciones no lineales en los datos, adaptándose a entornos volátiles y cambiantes [13].

Entre las arquitecturas más empleadas destacan las redes Multilayer Perceptron (MLP), útiles para tareas generales pero limitadas al no capturar dependencias temporales [14]. Para solventar esta limitación, surgieron las redes recurrentes (RNN) [15] y sus variantes LSTM [16] y GRU [17], capaces de mantener información del pasado y modelar relaciones a largo plazo de forma eficiente.

Modelos más recientes, como los basados en Transformers [18] (Informer [19], Autoformer [20], Temporal Fusion Transformer [21]), aprovechan mecanismos de atención para capturar dependencias de largo alcance y mejorar la paralelización. Asimismo, el modelo N-BEATS [22] diseñado específicamente para series temporales, prescinde de recurrencia y convolución, utilizando bloques residuales que combinan interpretabilidad y alto rendimiento.

Pese a sus ventajas, estos modelos requieren grandes volúmenes de datos, son propensos al sobreajuste y presentan dificultades de interpretación, lo que limita su aplicación directa en entornos financieros donde la transparencia es esencial [23].

2.1.4 Modelos híbridos

Los modelos híbridos combinan diferentes enfoques (estadísticos, de *machine learning* y de *deep learning*) con el objetivo de mejorar la precisión y la robustez de las predicciones [28]. Al integrar las ventajas de cada técnica, buscan compensar sus limitaciones y adaptarse mejor a la complejidad de los mercados financieros.

Estudios recientes, como el de Stempień y Ślepaczuk (2024) [24], demuestran que estas arquitecturas, donde un modelo estadístico realiza una predicción inicial y otro corrige los

errores residuales, superan en precisión a los modelos individuales y ofrecen mayor adaptabilidad a distintas condiciones del mercado.

Asimismo, enfoques basados en *ensemble learning* (como *stacking* o *blending*) combinan los resultados de modelos como Random Forest, XGBoost o redes neuronales en un metamodelo final, logrando predicciones más estables y precisas al reducir el sesgo y mejorar la generalización [25] [26].

2.1.5 Evolución

En la Ilustración 1 se presenta una cronología que resume la evolución de los distintos tipos de modelos de predicción de valores de activos financieros, destacando los hitos más representativos en cada etapa.




Ilustración 1. Evolución de los modelos para predicción financiera. Elaboración propia.

En la Tabla 1 se muestra la clasificación de modelos de series temporales financieras.

Tabla 1. Clasificación de modelos de predicción de series temporales. Elaboración propia.

Categoría	Modelos representativos	Naturaleza	Limitaciones principales
Tradicionales	ARIMA, GARCH	Lineales, paramétricos	Requieren estacionariedad
Machine Learning	SVM, RF, XGBoost	No lineales, estáticos	No capturan memoria temporal
Deep Learning	MLP, LSTM, N-BEATS, Transformer	Dinámicos, secuenciales	Requieren muchos datos
Híbridos	ARIMA+LSTM, TSFEDL (CNN+LSTM)	Combinados	Complejidad e interpretabilidad

2.1.6 Conclusiones del capítulo

En la Tabla 2, Tabla 3, Tabla 4 y Tabla 5 se resumen algunos trabajos representativos del estado del arte, indicando los datos empleados, los algoritmos aplicados y el resumen de cada uno.

Tabla 2. Estudio 1: Hybrid Models for Financial Forecasting: Combining Econometric, Machine Learning, and Deep Learning Models. Elaboración propia.

Título	Hybrid Models for Financial Forecasting: Combining Econometric, Machine Learning, and Deep Learning Models
Año	2024
Autores	Stempień y Ślepaczuk
Datos usados	Índice S&P 500 (2002-01-01 al 2023-12-31) Bitcoin (diario 2015-1-1 al 2023-12-31)
Algoritmos/técnicas	ARIMA–LSTM y ARIMA-SVN entre otros
Resumen	El estudio demuestra que combinar modelos lineales y no lineales mejora la precisión de las predicciones y permite captar mejor la complejidad de los mercados, generando resultados y estrategias más rentables que los métodos tradicionales.

Tabla 3. Estudio 2: Combining multiple feature selection methods for stock prediction: Union, intersection, and multi-intersection approaches. Elaboración propia

Título	Combining multiple feature selection methods for stock prediction: Union, intersection, and multi-intersection approaches
Año	2010
Autores	Chih-Fong Tsai, Yu-Chieh Hsiao
Datos usados	Datos trimestrales de 4.140 observaciones del sector electrónico taiwanés (2000–2007), con 85 variables fundamentales y macroeconómicas procedentes de la base de datos <i>Taiwan Economic Journal (TEJ)</i> .
Algoritmos/técnicas	Métodos de selección de características como PCA, Decision trees, o Genetic Algorithm. Redes neuronales MLP
Resumen	Distintos métodos de selección de características, como PCA, algoritmos genéticos y árboles de decisión, se combinan para generar un conjunto optimizado de variables que alimenta un modelo neuronal encargado de realizar la predicción

Tabla 4. Estudio 3: Stock Price Prediction Using Neural Network Models Based on Tweets Sentiment Scores. Elaboración propia.

Título	Stock Price Prediction Using Neural Network Models Based on Tweets Sentiment Scores
Año	2017
Autores	Anderson Rioba Ondieki, George Onyango Okeyo y Ann Kibe (Jomo Kenyatta University of Agriculture and Technology, Kenia)
Datos usados	Tweets de dos empresas cotizadas en Kenia recopilados entre septiembre y diciembre de 2015, junto con datos bursátiles diarios de precios y volumen.
Algoritmos/técnicas	Modelo neuronal Nonlinear Autoregressive Network with Exogenous Inputs (NARX), entrenado con variables técnicas y puntuaciones de sentimiento obtenidas mediante WordNet y SentiWordNet.
Resumen	El estudio muestra que añadir el sentimiento expresado en Twitter a los datos financieros mejora la precisión de los modelos neuronales al predecir precios bursátiles, demostrando que la información social puede aportar valor a las decisiones de inversión.

Tabla 5. Estudio 4: Deep Learning for Financial Time Series Prediction. Elaboración propia.

Título	Deep Learning for Financial Time Series Prediction
Año	2020
Autores	Sezer, O. B.; Gudelek, M. U.; y Ozbayoglu, A. M. (Middle East Technical University, Turquía)
Datos usados	DOW-30 index & ETFs, S&P 500, entre otros en varios periodos de tiempo.
Algoritmos/técnicas	ARIMA, SVN, LSTM, CSNN y CSNN-LSTM
Resumen	El estudio muestra que los modelos de <i>deep learning</i> , como las redes recurrentes y convolucionales, superan a los métodos tradicionales al predecir series financieras, ya que captan mejor las relaciones

	complejas del mercado, aunque requieren una optimización cuidadosa y una interpretación prudente.
--	---

2.2 Contexto y justificación

Los mercados financieros son altamente volátiles, y anticipar la evolución de los precios resulta clave para diseñar estrategias de especulación a utilizar en el trading algorítmico. En este contexto existe una creciente demanda de herramientas basadas en inteligencia artificial capaces de analizar datos históricos y detectar patrones útiles para la predicción.

Los modelos estadísticos suelen estar limitados por su linealidad, los modelos de machine learning no logran capturar bien dependencias temporales y aunque las redes neuronales profundas han demostrado buenos resultados, la literatura evidencia una falta de consenso sobre que arquitecturas se adaptan mejor a datos financieros intradía, donde la relación señal-ruido es muy baja.

En este contexto, este trabajo se justifica por la necesidad de probar modelos de *deep learning* que mejoren la precisión y la capacidad para anticipar la dirección del mercado en datos de alta frecuencia. A diferencia de los métodos tradicionales, estas redes pueden captar mejor los patrones temporales y adaptarse a distintas condiciones del mercado, lo que resulta clave para una aplicación especulativa real.

2.3 Planteamiento del problema

La predicción de precios de renta variable mediante inteligencia artificial es un desafío complejo, marcado por la alta volatilidad y la no linealidad de los mercados financieros. Los métodos estadísticos tradicionales ofrecen un rendimiento limitado, ya que no capturan con eficacia los patrones subyacentes en este tipo de datos.

Los avances en inteligencia artificial permiten detectar patrones más sofisticados en grandes volúmenes de información, aunque persisten retos clave como el ruido de los precios, la heterogeneidad entre activos, la selección y ajuste óptimo de los modelos y la evaluación rigurosa de su desempeño.

En este contexto, el presente trabajo aborda el desarrollo y evaluación de modelos predictivos a corto plazo aplicados a activos de renta variable, empleando un ETF sintético construido a partir de los datos históricos de cinco acciones tecnológicas, con el fin de determinar qué arquitecturas de inteligencia artificial ofrecen el mejor rendimiento predictivo.

Capítulo 3. OBJETIVOS

El objetivo principal de este trabajo de fin de Máster es mejorar la predicción de precios de activos de renta variable mediante el uso de modelos de inteligencia artificial. Para lograrlo, se propone comparar detalladamente diferentes enfoques y evaluar su rendimiento utilizando datos históricos de precios en intervalos horarios.

3.1 Objetivos generales

El objetivo general de este trabajo es evaluar el rendimiento predictivo de tres modelos de inteligencia artificial en la estimación del retorno de precios de un ETF sintético, construido a partir de los datos históricos horarios de cinco acciones del sector tecnológico durante un periodo de cuatro años.

Este análisis persigue un propósito estratégico de carácter especulativo, orientado a analizar en qué medida las predicciones generadas por los modelos pueden servir de apoyo a decisiones de inversión automatizadas dentro de un entorno de *trading* algorítmico.

3.2 Objetivos específicos

Para lograr el objetivo general establecido, se han fijado una serie de metas específicas que orientan la evolución del proyecto y estructuran las distintas etapas del trabajo. Estos objetivos permiten abordar de manera organizada y sistemática tanto los aspectos técnicos como los analíticos.

1. Seleccionar un conjunto representativo de activos bursátiles de un determinado sector económico, que permita analizar el comportamiento de modelos bajo condiciones similares de mercado.
2. Obtener y descargar los datos históricos de dichos activos en la frecuencia temporal definida para el estudio.
3. Depurar y preparar los datos recopilados, aplicando los procesos de limpieza, transformación y normalización.
4. Construir un ETF sintético a partir de los activos seleccionados, definiendo su metodología de ponderación y cálculo de precios y retornos.
5. Realizar un análisis exploratorio de datos (EDA) sobre el ETF sintético resultante para identificar patrones, correlaciones y características relevantes.
6. Selección e implementación de 3 modelos del estado del arte con enfoques distintos, aplicados a este problema e implementarlos:
 - a. Modelo red neuronal Recurrente (LSTM)
 - b. Modelo no recurrente para series temporales (N-BEATS)
 - c. Modelo híbrido TSFEDL (CNN + RNN)
7. Evaluar el rendimiento predictivo de cada modelo, utilizando métricas como el error medio absoluto (MAE), el error cuadrático medio (MSE), la raíz del error cuadrático

medio (RMSE), el coeficiente de determinación (R^2), la precisión direccional, y el ratio de Sharpe simulado.

8. Comparar los resultados entre modelos para identificar:
 - a. Las fortalezas y debilidades de cada modelo.
 - b. Determinar cuál ofrece el mejor rendimiento para la predicción de precios.

3.3 Beneficios del proyecto

Este proyecto aporta beneficios tanto en el ámbito académico como en el práctico. Se destacan siguientes:

- **Aporta conocimiento útil:** el estudio proporcionará información valiosa para mejorar la comprensión del comportamiento de distintos modelos de inteligencia artificial aplicados a la predicción de precios. La comparación de los resultados permitirá identificar las fortalezas y debilidades de cada modelo, y determinar cuál es el más adecuado para un objetivo especulativo.
- **Una metodología clara y generalizable:** tanto los métodos y scripts empleados para adquirir y preprocesar los datos como para entrenar los modelos serán generalizables para otros tipos de stocks y otros tipos de modelos.
- **Aplicabilidad en el mundo real:** los hallazgos de este proyecto podrían tener aplicaciones prácticas significativas, ya que proporcionarán información sobre qué modelos tienen una mejor capacidad predictiva y cuáles son más eficaces en la toma de decisiones del mundo real. Asimismo, los resultados podrían contribuir a mejorar el rendimiento y la gestión de carteras basadas en ETFs, al facilitar la selección de estrategias más precisas y robustas desde el punto de vista predictivo.
- **Desarrollo de habilidades técnicas:** durante el proyecto se trabajará en el desarrollo de habilidades técnicas que implicarán la aplicación de conocimientos sobre análisis de datos financieros, uso de modelos de inteligencia artificial, programación y evaluación de modelos; habilidades potencialmente valoradas en el mundo laboral.

Capítulo 4. DESARROLLO DEL PROYECTO

Este capítulo describe en detalle el proceso seguido para diseñar, implementar y evaluar un sistema de predicción de cotizaciones bursátiles basado en técnicas de inteligencia artificial.

4.1 Planificación del proyecto

En este apartado se detalla la programación del proyecto, indicando las principales fases desarrolladas y las fechas aproximadas de inicio y finalización de cada una. La Ilustración 2, muestra esta planificación.




Ilustración 2. Planificación del proyecto. Elaboración propia.

4.2 Descripción de la solución, metodologías y herramientas empleadas

En este apartado se describe la solución propuesta para abordar el problema de predicción de cotizaciones de activos de renta variables mediante técnicas de inteligencia artificial.

4.2.1 Metodología

El desarrollo del proyecto se ha organizado siguiendo la metodología Cross-Industry Standard Process for Data Mining (CRISP-DM) [27], ampliamente utilizada en el campo de la ciencia de datos. Esta metodología establece un ciclo iterativo conformado por seis etapas fundamentales: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación e implementación. En la Ilustración 3 se muestran las fases de esta metodología.




Ilustración 3. Diagrama CRISP-DM [27]

En los apartados siguientes se describen las fases del proyecto según la metodología CRISP-DM, desde la recopilación y preparación de los datos hasta el entrenamiento y evaluación final de los modelos.

El código fuente completo utilizado en esta tesis se encuentra disponible en un repositorio público de GitHub [28], con el fin de promover la reproducibilidad de los experimentos realizados.

4.2.1.1 Comprensión del negocio.

El objetivo de este trabajo es mejorar la predicción de los precios de un ETF sintético, construido a partir de 5 acciones del sector tecnológico, mediante el uso de técnicas *deep learning* de inteligencia artificial, con un objetivo especulativo.

Se busca evaluar el rendimiento de distintos modelos, con el fin de identificar cuáles ofrecen mayor precisión y robustez en contextos reales de alta volatilidad y complejidad.

4.2.1.2 Comprensión de los datos.

Se ha recopilado un conjunto de datos históricos correspondiente a cinco activos bursátiles del sector tecnológico. Partiendo de estos datos, se ha creado un ETF sintético. Los datos consisten en series temporales de “precio de cierre” (en dólares) y “volumen” (número total de unidades

de un activo financiero que se negocian en un periodo de tiempo determinado) con una frecuencia horaria, abarcando un periodo de cuatro años. Esta granularidad permite capturar tanto patrones intradía como tendencias a medio plazo. Durante esta fase se desarrolló un análisis exploratorio de los datos (EDA) para el ETF sintético, examinando su distribución, estacionalidad, correlaciones, valores atípicos, con el fin de comprender su comportamiento y adaptar los modelos a sus características.

4.2.1.2.1 Activos bursátiles seleccionados

Para el desarrollo del proyecto se seleccionaron cinco acciones del sector tecnológico, por tres motivos principales:

1. Homogeneidad sectorial: Los activos de una misma industria suelen mostrar comportamientos similares, lo que permite realizar comparaciones más coherentes y relevantes [29].
2. Interés práctico: El sector tecnológico ha sido uno de los más influyentes en los mercados financieros durante la última década [30]. Analizarlo permite validar la aplicabilidad de los modelos en un contexto real de alta volatilidad y complejidad.
3. Interés personal: La elección también responde al interés del autor por la innovación tecnológica y el impacto de estas compañías en la economía actual, lo que aporta una motivación adicional y una comprensión más profunda del comportamiento de sus acciones.

Lo activos bursátiles seleccionados y mostrados en la Tabla 6, pertenecen a algunas de las empresas tecnológicas más representativas y con mayor capitalización bursátil del mercado estadounidense.

Tabla 6. Activos seleccionados. Elaboración propia.

Empresa	Ticker	Mercado	Sector
Apple Inc.	AAPL	NASDAQ	Tecnología
Microsoft Corporation	MSFT	NASDAQ	Tecnología
NVIDIA Corporation	NVDA	NASDAQ	Tecnología
IBM	IBM	NASDAQ	Tecnología
Google	GOOG	NASDAQ	Tecnología

El conjunto de datos abarca un periodo de cuatro años (2021-2024) con frecuencia horaria, incluyendo el “precio de cierre”, y “volumen” de negociación. Este marco temporal ofrece un equilibrio adecuado entre detalle y volumen de datos, suficiente para capturar tanto patrones intradías como tendencias de medio plazo [31].

La selección de estos cinco activos proporciona una base sólida, homogénea y representativa del mercado tecnológico, sobre la que se construyó el ETF sintético empleado en las fases posteriores del proyecto.

4.2.1.2.2 Fuentes de datos

Los precios históricos de los activos se obtuvieron del proveedor Polygon.io mediante llamadas a su API. Las tablas Tabla 7, Tabla 8 y Tabla 9, muestran las principales características de los orígenes de datos utilizados.

Tabla 7. Origen de datos de precios. Elaboración propia.

Proveedor	https://polygon.io/
Activos	AAPL, MSFT, NVDA, IBM, GOOG
Frecuencia y horizonte temporal	Velas OHLCV horarias, 2021-01-01 a 2024-12-31
Variables descargadas	datetime, open, high, low, close, volume, vwap
Formato y tamaño	CSV, 4.21 MB, codificación UTF-8
Licencia / uso	Datos de pago, licencia para uso personal o académico
Procedimiento de descarga	API REST [32]

Las capitalizaciones de mercado de las cinco acciones se obtuvieron de Polygon.io mediante su API.

Tabla 8. Origen de datos de capitalizaciones de mercado. Elaboración propia.

Proveedor	https://polygon.io/
Activos	AAPL, MSFT, NVDA, IBM, GOOG
Fecha de referencia (t_0)	01/09/2025
Variables descargadas	stock, market_cap
Formato y tamaño	JSON, 4Kb, codificación UTF-8
Licencia / uso	Datos de pago, licencia para uso personal o académico
Procedimiento de descarga	API REST [32]

Las series del Secured Overnight Financing Rate (SOFR) y del CBOE Volatility Index (VIX) se obtuvieron de la base de datos Federal Reserve Bank of St.Louis (FRED) [33]. Los datos descargados cubren el periodo 2021-01-01 a 2024-12-31, en frecuencia diaria, y se emplearon como variables macroeconómicas de referencia para la modelización.

Tabla 9. Origen de datos de variables macroeconómicas. Elaboración propia.

Proveedor	FRED
Índices	SOFR, VIX
Frecuencia y horizonte temporal	Fecha y valores diarios, 2021-01-01 a 2024-12-31
Variables descargadas	fecha, valor de cierre
Formato y tamaño	CSV, 40 Kb, codificación UTF-8
Licencia / uso	Datos de uso gratuito para uso académico
Procedimiento de descarga	Descarga manual vía web

4.2.1.3 Preparación de los datos.

En esta fase se llevó a cabo la limpieza, transformación y estructuración de los datos para garantizar su calidad y formato esperado por los modelos.

4.2.1.3.1 Selección de variables relevantes

Con el objetivo de reducir la dimensionalidad y mantener solo la información necesaria para el posterior análisis y modelado, se realizó una selección de campos de los datos en bruto descargado. Para cada activo, de cada registro horario se conservaron exclusivamente las columnas:

- “datetime”: campo temporal en formato ISO 8601, utilizada como índice de la serie.
- “close”: precio de cierre de cada intervalo horario, que sirve como base para el cálculo de rendimientos logarítmicos.
- “volumen”: volumen de negociación correspondiente a cada intervalo, empleado como indicador de liquidez.

4.2.1.3.2 Alineación temporal y tratamiento de valores faltantes

Para garantizar la coherencia de todas las series temporales de los datos en bruto de cada activo, se realizó una alineación temporal a una frecuencia uniforme en zona horaria oficial del Nasdaq (Eastern Time ET). Se generó un índice cronológico continuo con intervalos exactos de una hora. Durante esta operación se detectaron huecos en los datos debidos a fines de semana, festivos o interrupciones en las fuentes. Para mantener la consistencia del conjunto se aplicó un procedimiento de imputación *forward-fill*, con las siguientes particularidades:

- El valor de “close” se completó con el último valor conocido.
- El valor de “volumen” se imputó a 0, para las noches, fines de semana, festivos y otras franjas faltantes, en lugar de crear un volumen artificial, para preservar la información de “sin actividad”.

Este enfoque permite disponer de series temporales completas sin introducir sesgos significativos en la modelización.

4.2.1.3.3 Cálculo de los retornos logarítmicos

El uso de los retornos logarítmicos (*log-returns*) ofrece varias ventajas: es aditivo en el tiempo (la suma de los *log-returns* en intervalos cortos equivale al *log-return* del período total), estabiliza la varianza, y en muchos casos, produce distribuciones más cercanas a la normalidad, especialmente en escalas temporales cortas. Estas propiedades lo convierten en una métrica adecuada para el modelado y la predicción mediante técnicas estadísticas y de inteligencia artificial. Además, facilita la interpretación porcentual de los cambios, lo que es especialmente útil en contextos financieros.

En este trabajo, todos los modelos han sido entrenados y evaluados utilizando *log-returns* como variable objetivo.

La transformación de precios absolutos a *log-returns* se define como:

$$R_t = \ln\left(\frac{P_t}{P_{t-1}}\right)$$

donde P_t es el precio del activo en el momento t , y P_{t-1} es el precio en el periodo anterior [34].

4.2.1.3.4 Tratamiento de valores atípicos

Con el fin de detectar posibles errores o saltos anómalos (*outliers*) en los precios horarios de cada activo, se realizó un análisis de valores atípicos sobre la serie de *log-returns*.

Se calcularon la media μ_i y la desviación estándar σ_i de la serie de *log-returns*. Se identificó como *outlier* cualquier observación que cumpliera:

$$|\log_return_{i,t} - \mu_i| > 3 \sigma_i$$

Dado que los *log-returns* suelen tener colas más pesadas que la normal, usar ± 3 desviaciones estándar es una práctica común para detectar movimientos inusuales.

Se identificaron varias observaciones fuera del rango habitual. Sin embargo, tras un análisis más detallado se determinó que dichos valores no constituían errores de medición ni inconsistencias en los datos, sino que correspondían a fluctuaciones propias del comportamiento esperado en retornos horarios de activos bursátiles.

Por este motivo, en esta fase no se aplicó ningún procedimiento de corrección o eliminación. Se decidió posponer su tratamiento para la etapa de construcción del ETF sintético, donde los *log-returns* de los distintos activos se combinarán y, en caso necesario, se aplicarán técnicas de tratamiento de *outliers*.

Este tratamiento permitió garantizar que la base de datos en el modelado no contuviera distorsiones debidas a datos erróneos.

El porcentaje de *outliers* detectados mediante este criterio fue inferior al 2.45 % (véase Tabla 10) en todos los activos.

Tabla 10. Outliers en los activos. Elaboración propia.

Activo	Número de registros	Número de outliers	Porcentaje de Outliers
AAPL	34981	789	2.26 %
MSFT	34981	767	2.19 %
NVDA	34981	851	2.43 %
IBM	34981	675	1.93 %
GOOG	34981	763	2.18 %

De manera complementaria, también se realizó la detección de valores atípicos en la variable “volumen”. Aunque se identificaron observaciones con magnitudes significativamente superiores a la media, estas se interpretaron como episodios normales en los mercados financieros, asociados a incrementos puntuales de la actividad de negociación. En consecuencia, dichos valores no fueron considerados anomalías y no se aplicó ningún procedimiento de corrección en esta fase.

4.2.1.3.5 Construcción del ETF sintético

Con el objetivo de disponer de una única serie temporal representativa del conjunto de activos seleccionados, se procedió a la construcción de un ETF sintético que actúa como variable objetivo del estudio.

Se calcularon los pesos ponderados w_i de cada activo. Estos se determinaron en función de su capitalización bursátil en la fecha de referencia t_0 . Para ello se obtuvo la capitalización de mercado de cada una de las cinco acciones en esa fecha y, posteriormente, se calculó el peso relativo de cada activo como su capitalización dividida entre la suma total de capitalizaciones.

$$w_i = \frac{CapMercado_{i,t_0}}{\sum_{j=1}^N CapMercado_{j,t_0}}$$

donde, $CapMercado_{i,t_0}$ es la capitalización de mercado del activo i en la fecha de referencia t_0 , y N es el número de activos.

Se obtuvo el retorno logarítmico del ETF sintético como combinación lineal ponderada de los retornos logarítmicos de cada activo, según la formula:

$$r_{ETF,t} = \sum_{i=1}^N w_i r_{i,t}$$

donde, $r_{ETF,t}$ es el retorno logarítmico del ETF sintético en el instante t , w_i el peso asignado al activo i , $r_{i,t}$ es el retorno logarítmico del activo i en el instante t , y N es el número de activos.

Los *outliers* no se trataron en los *log-returns* individuales de cada acción, dado que se consideraron parte de la dinámica natural de los activos. En cambio, se aplicó el tratamiento de *outliers* en este punto, una vez construida la serie de *log-returns* del ETF sintético, garantizando así que los precios acumulados del ETF no quedasen distorsionados por valores extremos puntuales.

Se detectaron 869 outliers, lo que representa aproximadamente el 2.48 % de las observaciones, aplicando el criterio de detección basado en el rango de ± 3 desviaciones típicas respecto a la media. Con el fin de evitar que dichos valores extremos distorsionaran el cálculo posterior de la serie de precios, se procedió a su tratamiento mediante la técnica de *clipping*, sustituyendo los valores que excedían los umbrales definidos por los límites superior e inferior establecidos.

En la Ilustración 4 se muestran los *outliers* detectados en la serie de *log-returns* del ETF.




Ilustración 4. Outliers de los "log-returns" del ETF. Elaboración propia.

El campo precio de cierre del ETF sintético en cada instante t se reconstruyó a partir de los *log-returns* mediante la formula:

$$P_{ETF,t} = P_{ETF,0} \times \exp\left(\sum_{k=1}^t r_{ETF,k}\right)$$

donde, $P_{ETF,0}$ es el precio base establecido a 100.

La Ilustración 5 muestra la evolución temporal del precio del ETF sintético reconstruido a partir de los *log-returns*.



Ilustración 5. Precio reconstruido del ETF. Elaboración propia.

4.2.1.3.6 Ingeniería de variables

4.2.1.3.6.1 Variables temporales

A partir de la fecha de cada registro se crearon variables de calendario (hora del día, día de la semana y mes del año) para detectar posibles patrones intradía, efectos de fin de semana y variaciones estacionales en los retornos.

4.2.1.3.6.2 Volumen del ETF

Para estimar el volumen total del ETF sintético se utilizó la técnica llamada *dollar-volume aggregation*, que consiste en que cada instante t se multiplica el precio de cierre de cada activo por su volumen negociado, se pondera por el peso asignado en el ETF y finalmente, se divide entre el precio del ETF. Las fórmulas que se aplicaron se muestran en el Apéndice A.

Con el objetivo de reducir la asimetría positiva y la alta dispersión, se aplicó una transformación logarítmica, obteniendo así la variable “log_volume”, definida como:

$$\log_volume_t = \log(volume_t + 1)$$

En lugar de utilizar directamente la forma tradicional $\log(x + 1)$, se empleó la función $\log1p(x)$ disponible en la biblioteca NumPy de Python. Esta función calcula $\log(x + 1)$, de manera numéricamente más precisa, especialmente cuando los valores de x son pequeños, evitando la pérdida de precisión en punto flotante debido a limitaciones en la representación numérica.

Esta transformación permite estabilizar la varianza, suavizar los efectos de valores extremos.

4.2.1.3.6.3 Variables macro financieras exógenas

Se incorporaron dos variables macro financieras externas por su influencia en la liquidez y el sentimiento del mercado: SOFR y el VIX.

El SOFR representa el coste del financiamiento overnight garantizado con bonos del Tesoro de EE. UU. y se publica diariamente por la Reserva Federal de Nueva York. Es una referencia clave para medir las condiciones de liquidez del sistema financiero.

El VIX, calculado por el Chicago Board Options Exchange, mide la volatilidad esperada del mercado estadounidense en los próximos 30 días a partir de las opciones del S&P 500. Conocido como el “índice del miedo”, refleja el nivel de incertidumbre de los inversores: valores bajos (< 15) indican estabilidad, entre 15 y 25 una volatilidad moderada, y superiores a 30 una alta tensión en los mercados.

4.2.1.3.6.4 Indicadores técnicos

Para enriquecer las variables predictoras y capturar patrones de tendencia, *momentum*, volatilidad y volumen, se calcularon distintos indicadores técnicos a partir de las series horarias de precios y volumen del ETF sintético. Estos indicadores, habituales en el análisis cuantitativo y el *trading* algorítmico, aportan información adicional a los retornos logarítmicos, ayudando a los modelos de *deep learning* a detectar relaciones no lineales más complejas en los datos.

Indicadores de tendencia EMA10, EMA50 y EMA200. La Media Móvil Exponencial (EMA) pondera más los datos recientes. Se emplean tres horizontes (10, 50 y 200) para capturar tendencias de corto, medio y largo plazo. Su fórmula es:

$$EMA_t = \alpha \times Close_t + (1 - \alpha) \times EMA_{t-1}$$

donde, $\alpha = \frac{2}{N+1}$, y N es el número de periodos (10, 50 o 200).

Para reflejar la dinámica de las tendencias a corto y largo plazo, se creó la variable “ema_ratio”, definida como el cociente entre la media móvil exponencial corta (EMA10) y la media móvil exponencial larga (EMA20) calculadas sobre el precio de cierre. Esta relación permite identificar la pendiente de la tendencia: valores mayores que 1 indican un posible movimiento alcista, mientras que valores menores que 1 apuntan a una tendencia bajista. Su fórmula es:

$$ema_ratio_t = \frac{EMA_{10,t}}{EMA_{20,t}}$$

donde, P_t es el precio en el instante t.

Para medir la distancia entre las tendencias de corto y largo plazo, se definió la variable “ema_spread”, calculada como la diferencia entre la EMA10 y la EMA50 del precio de cierre. Valores positivos indican una tendencia alcista, mientras que los negativos reflejan una tendencia bajista. Además, la magnitud del indicador representa la intensidad de dicha tendencia. Su fórmula es:

$$ema_spread_t = EMA_{20,t} - EMA_{10,t}$$

Se incluyeron indicadores de *momentum* basados en medias móviles, en particular el oscilador MACD y sus componentes derivados (línea de señal e histograma), que permiten evaluar la fuerza y dirección del movimiento del precio. Estas tres variables permiten detectar cruces y separaciones que suelen anticipar cambios de tendencia, aportando información relevante para la predicción de retornos en el ETF sintético. Sus fórmulas son:

$$MACD_t = EMA_{12,t} - EMA_{26,t}$$

$$macd_signal_t = EMA_9(MACD_t)$$

$$macd_histogram_t = MACD_t - macd_signal_t$$

Se incorporó un indicador de volatilidad a 24 horas para medir la magnitud de las fluctuaciones recientes del precio. Este indicador calcula la dispersión de los retornos logarítmicos dentro de una ventana móvil de 24 periodos horario. El resultado refleja la variabilidad intradía: valores altos indican movimientos de precio más bruscos, mientras que valores bajos implican estabilidad relativa. Su fórmula es:

$$volatility_{24h_{24h,t}} = \sqrt{\frac{1}{24} \times \sum_{k=0}^{23} (r_{t-k} - \bar{r}_{24h})^2}$$

Donde, r_{t-k} es el retorno logarítmico horarios, y $\bar{r}_{24h}$ es la media de los retornos logarítmicos en la ventana de 24 horas.

Se incorporó el indicador On-Balance Volume (OBV), que combina la dirección del precio con el volumen negociado, actuando como una estimación del flujo de capital y como una herramienta útil para confirmar o anticipar tendencias del mercado. Su fórmula es:

$$OBV_t = OBV_{t-1} + sign(Close_t - Close_{t-1}) \times Volume_t$$

donde, $sign(x)$ vale **+1** si $x > 0$, vale **-1** si $x < 0$, o **0** si $x = 0$. El primer OBV_t se inició a 0.

4.2.1.3.6.5 Variable objetivo

Para el entrenamiento de los modelos se definió como variable objetivo el retorno logarítmico del periodo siguiente. Este se obtuvo desplazando la serie de *log-returns* un paso hacia adelante, de modo que cada observación en t se asoció con el retorno correspondiente a $t + 1$. El último registro, al no disponer de un valor futuro, resultó en NaN y fue eliminado. La fórmula utilizada fue:

$$target_log_return_t = log_return_{t+1}$$

4.2.1.3.7 División en conjuntos de entrenamiento, validación y prueba

Para garantizar una evaluación objetiva del rendimiento de los modelos y evitar el *data leakage*, el conjunto de datos se dividió en tres subconjuntos cronológicos: entrenamiento (*train*), validación (*validation*) y prueba (*test*).

Dado que se trata de una serie temporal, la partición respetó el orden temporal con el fin de simular un escenario real de predicción futura. La división se realizó en intervalos de días completos y quedó establecida de la siguiente forma:

- **Entrenamiento (70%):** utilizado para ajustar los parámetros de los modelos.
- **Validación (15%):** empleado para afinar los hiperparámetros y detectar *overfitting*.

- **Prueba (15 %):** reservado para la evaluación final del rendimiento del modelo

4.2.1.3.8 Escalado de los datos

Para asegurar que todas las variables tuvieran rangos comparables y evitar que las diferencias de escala afectaran al entrenamiento, se aplicaron los siguientes métodos de normalización:

- **MinMaxScaler**, para todas las variables de entrada, excepto “datetime” y “log_return”. Cada columna contó con su propio escalado.
- **StandardScaler** (media 0, desviación típica 1) aplicado a “log_return” y a la variable objetivo “target_log_return”

El escalado se ajustó únicamente con los datos de entrenamiento y luego se aplicó a los conjuntos de validación y prueba, evitando así cualquier forma de *data leakage*.

4.2.1.3.9 Resumen de variables finales

El conjunto de datos final utilizado para el modelado quedó formado por las variables mostradas en la Tabla 11.

Tabla 11. Resumen de variables. Elaboración propia.

Variable	Tipo	Unidad/Escala	Descripción breve
datetime	Temporal	adimensional	Fecha de la muestra
close	Float	Dólares (\$)	Precio de cierre del ETF sintético.
volume	Float	participaciones	Volumen agregado mediante dollar-volume aggregation.
log_volume	Float	adimensional	Logaritmo natural de 1 + volumen
date_hour	Entero	adimensional	Hora del día del período
date_day	Entero	adimensional	Día de la semana del período
date_month	Entero	adimensional	Mes del año del período
ema10	Float	Dólares (\$)	Media móvil exponencial de 10
ema50	Float	Dólares (\$)	Media móvil exponencial de 50
ema200	Float	Dólares (\$)	Media móvil exponencial de 200
ema_ratio	Float	adimensional	
ema_below	Float	adimensional	
macd	Float	Adimensional	Indicador de momentum basados en medias móviles
macd_signal	Float	adimensional	

macd_histogram	Float	adimensional	
volatility_24h	Float	adimensional	Desviación estándar de <i>log-returns</i> en ventana de 24 h.
obv	Float	participaciones	On-Balance Volume acumulativo.
sofr	Float	% anual	Es una tasa de interés overnight de la Reserva Federal; se publica como porcentaje anual.
vix	Float	Porcentaje de volatilidad implícita anualizada (%)	Representa la volatilidad esperada a 30 días del S&P 500, expresada en puntos de porcentaje .
log_return	Float	adimensional	Retorno logarítmico entre cierres consecutivos.
target_log_return	Float	adimensional	Retorno logarítmico esperado entre cierres consecutivos. Esta es la variable objetivo.

4.2.1.4 Análisis exploratorio de datos sobre el ETF sintético (EDA)

Este apartado tiene como objetivo describir las principales características del conjunto de datos, identificar patrones temporales y relaciones entre variables, y detectar posibles anomalías que puedan afectar el modelado posterior.

4.2.1.4.1 Descripción general del conjunto de datos

- Periodo temporal 01/01/2021 hasta 31/12/2024
- Frecuencia horaria
- Registros: 34980

Los estadísticos descriptivos básicos de las variables del dataset se muestran en la Tabla 12.

Tabla 12. Estadísticos descriptivos de las variables. Elaboración propia.

	Mean	min	25%	50%	75%	max	Std
date_hour	11.50	0.0	6.0	12.0	18.0	23.0	6.92
date_day	2.99	0.0	1.0	3.0	5.0	6.0	2.0004
date_month	6.53	1.0	4.0	7.0	10.0	12.0	3.44
close	225.86	96.13	145.90	176.54	281.63	492.62	106.96
volume	1342927.43	0.0	0.0	0.0	366759	26229529	2827167.08

	Mean	min	25%	50%	75%	max	Std
log_volume	6.0414	0.0	0.0	0.0	12.81	17.08	6.76
ema10	225.80	96.73	146.04	176.42	281.77	491.33	106.93
ema50	225.36	97.64	146.13	177.25	280.97	488.33	106.66
ema200	223.57	98.56	146.30	175.14	278.99	481.12	105.39
ema_ratio	1.0018	0.96	0.9951	1.0026	1.0087	1.0359	0.010129
ema_spread	0.4388	-10.2705	-0.9719	0.5372	1.7869	9.5490	2.260061
macd	0.1436	-4.8342	-0.4608	0.1735	0.7473	4.6976	0.99511
macd_signal	0.1544	-4.3519	-0.4231	0.1773	0.7271	4.2511	0.935791
macd_histogram	-0.01078	-1.6299	-0.1604	-0.0044	0.1409	1.5633	0.281683
volatility_24h	0.001989	0.0	0.00046	0.00220	0.0030	0.0061	0.001421
obv	894781863.7	-98685357	302669621.2	6846133 41.	1362071 648	204551738 6	657528588.1
sofr	0.0296	0.0001	0.0005	0.043	0.053	0.054	0.023125
vix	19.3218	11.86	15.1	18.39	22.21	38.57	5.262916
log_return	0.000045	-0.009177	0.0	0.0	0.0	0.009243	0.002453
target_log_return	0.000045	-0.009177	0.0	0.0	0.0	0.009243	0.002453

4.2.1.4.1.1 Calidad y estructura de los datos

Se realizaron las siguientes validaciones sobre el dataset generado:

- **Integridad temporal:** se constató que la columna “datetime” siguiera una secuencia estrictamente creciente con intervalos exactos de una hora entre registros. No se detectaron huecos ni duplicados.
- **Valores nulos:** se revisaron todas las variables y no se encontraron valores NaN ni filas repetidas, por lo que no fue necesario aplicar imputaciones ni eliminaciones.

- **Rangos de valores:** se validaron los rangos de las variables principales para garantizar la ausencia de valores imposibles:
 - “close”: positivo y entre 50 y 400 USD.
 - “volumen”: positivo.
 - variables de calendario (date_day, date_hour, date_month) dentro de sus dominios esperados (1-31, 0-23 y 1-12).

4.2.1.4.2 Estacionalidad de los retornos logarítmicos

La Ilustración 6 compara el precio de cierre y los *log-returns* del ETF sintético. Se aprecia una clara tendencia creciente en el precio, mientras que los *log-returns* oscilan alrededor de cero, sin tendencia, reflejando su carácter estacionario.

La prueba Dickey-Fuller aumentada (ADF) sobre los *log-returns*, arrojó un estadístico ADF de -34 y un valor p de 0.000, lo cual es significativamente menor al umbral convencional de 0.05, lo que, junto con la observación visual confirma que los retornos logarítmicos son estacionarios a diferencia de los precios (ADP = 1.47 y valor p = 0.9974).




Ilustración 6. (a) Serie temporal de precio. (b) Serie temporal de log-returns. Elaboración propia.

4.2.1.4.3 Detección de valores atípicos

En esta etapa se aplicó un proceso sistemático de detección de *outliers* sobre las variables numéricas del conjunto de datos, utilizando el criterio de ± 3 desviaciones estándar respecto a la media. La variable “log_return” no se analizó en esta fase ya que los valores extremos fueron tratados previamente durante la construcción del ETF sintético.

La Tabla 13 muestra los valores atípicos identificados en el conjunto de datos tras aplicar el criterio de ± 3 desviaciones estándar:

Tabla 13. *Outliers en el conjunto de datos final. Elaboración propia.*

Variable	Número de registros	Número de <i>outliers</i>	Porcentaje de <i>outliers</i>
volume	34980	801	0.17 %
ema_ratio	34980	215	0.61 %
ema_spread	34980	423	1.21 %
macd	34980	398	1.14 %
macd_signal	34980	376	1.07 %
macd_histogram	34980	433	1.24 %
vix	34980	96	0.27 %

Ninguno de estos valores se consideró un error o anomalía, al contrario, son eventos reales que aportan información valiosa para la modelización predictiva. En consecuencia, no se realizó eliminación ni recorte de *outliers*, manteniendo todos los datos para preservar la integridad de las señales financieras presentes en el conjunto de datos.

4.2.1.4.4 Estadística univariante avanzada

Se analizaron los histogramas de las variables numéricas para evaluar la forma de sus distribuciones y detectar posibles asimetrías o valores extremos. En el caso de variables muy correlacionadas, se mostraron solo los histogramas más representativos para evitar redundancia.

La Ilustración 7 muestra histograma de “log_return”, donde se aprecia una fuerte concentración en torno a 0, lo que indica que la mayoría de los movimientos de precio son pequeños, algo típico en series financieras de alta frecuencia. Las colas largas en ambos extremos revelan episodios de gran volatilidad, mientras que la forma casi simétrica sugiere una frecuencia similar de subidas y bajadas. La distribución muestra curtosis positiva y colas gruesas, lo que indica una mayor probabilidad de movimientos extremos en comparación con una distribución normal. En el histograma se observan dos pequeñas acumulaciones en los extremos del rango, alrededor de -0.010 y 0.010, estas no corresponden a una alta frecuencia natural de esos valores, sino que son consecuencia del *clipping* aplicado al tratar los *outliers*.




Ilustración 7. Histograma de log-returns horarios. Elaboración propia.

La Ilustración 8 muestra histograma de “close”, donde se aprecia una distribución multimodal con varios picos, concentrando los precios en los rangos 100–180, 220–277, 320–360, y 390–480. Este patrón sugiere la presencia de distinto regímenes de mercado a lo largo del periodo analizado y pone en relieve la conveniencia de emplear modelos capaces de capturar tanto las no linealidades como cambios de tendencia.




Ilustración 8. Histograma de precios de cierre. Elaboración propia.

La Ilustración 9 muestra el histograma de “volume”, donde se aprecia una asimetría hacia la derecha, con una densa agrupación alrededor de cero (períodos sin actividad) y una cola larga que refleja episodios esporádicos de elevado volumen.




Ilustración 9. Histograma de “volume”. Elaboración propia.

La Ilustración 10 muestra el histograma de la variable “log_volume”, el cual presenta un primer pico en 0, correspondiente a periodos sin actividad de negociación, y después muestra un segundo conjunto de valores entre 10 y 17, reflejando intervalos con volumen positivo. La aplicación de la transformación logarítmica atenúa la varianza de los datos, pero al mismo tiempo preserva la señal de ausencia de actividad.




Ilustración 10. Histograma de log_volume. Elaboración propia.

Dado que las EMAs (10, 50 y 200 periodos) son versiones suavizadas del precio de cierre, sus histogramas (Ilustración 11) muestran una forma casi idéntica a la distribución del “close”. Al igual que este, presentan un sesgo a la derecha, con una cola extendida hacia precios altos. La Tabla 14 muestra como la media y la desviación estándar disminuye ligeramente conforme aumenta la ventana de cálculo.

Tabla 14. Estadísticos de las EMAs

Variable	EMA10	EMA50	EMA200
Media	225.807	225.368	223.573
Desviación estándar	106.936	106.668	105.399




Ilustración 11. Histogramas de EMA10, EMA50 y EMA200. Elaboración propia.

La Ilustración 12 muestra el histograma de la variable “ema_ratio”, donde se observa una distribución estrecha y centrada en torno a 1, con valores que oscilan entre 0.96 y 1.04. Esto indica que las EMAs rápida y lenta suelen tener valores muy similares, lo que refleja un mercado en gran medida estable. En este contexto, “ema_ratio” igual 1 indica equilibrio, valores superiores señalan un impulso alcista, y valores inferiores un impulso bajista.




Ilustración 12. Histograma de ema_ratio. Elaboración propia.

La Ilustración 13 muestra el histograma de “ema_spread”, el cual presenta una distribución casi normal, centrada en 0, con valores que oscilan entre -10 y 10. En consecuencia, la mayor parte del tiempo las EMAs quedan prácticamente alineadas, solo en casos poco frecuentes aparecen diferencias amplias.




Ilustración 13. Histograma de ema_spread. Elaboración propia.

La Ilustración 14 muestra el histograma de la variable “macd”, la cual presenta una distribución casi normal, centrada en 0, con valores entre -5 y 5. Su simetría indica que los episodios alcistas y bajistas ocurren con frecuencias similares.




Ilustración 14. Histograma de macd. Elaboración propia.

No se incluyen histogramas separados de “macd_signal” ni de “macd_histogram”, puesto que ambas variables derivan del MACD y presentan una distribución semejante, aunque con una ligera atenuación y un rango más estrecho. La Tabla 15 muestra sus estadísticos.

Tabla 15. Estadísticos de macd. Elaboración propia.

Variable	macd	macd_signal	macd_histogram
Media	0.143	0.154	-0.01077
Desviación estándar	0.995	0.935	0.28168
Rango	9.531	8.603	3.19326

La Ilustración 15 muestra el histograma de volatilidad a 24 horas, donde el pico que aparece cerca de 0 corresponde a los períodos sin actividad. Este patrón permite distinguir los intervalos de inactividad de los episodios de volatilidad real, proporcionando información útil para el modelado.




Ilustración 15. Histograma de volatility24h. Elaboración propia.

La Ilustración 16 muestra el histograma de la variable “obv”, el cual presenta una distribución amplia, ya que este indicador suma o resta volumen según el precio cierra al alza o a la baja. La ausencia de valores negativos y la acumulación de la mayor parte de los datos en niveles altos ponen de manifiesto el predominio del volumen comprador.




Ilustración 16. Histograma de obv. Elaboración propia.

La Ilustración 17 muestra el histograma de la variable “vix”, la cual presenta una distribución sesgada a la derecha, con la mayoría de los valores entre 5 y 23 y una cola que se extiende hasta alrededor de 35-40. Este patrón sugiere que el mercado suele atravesar extensos periodos de volatilidad moderada, interrumpidos ocasionalmente por episodios de alta incertidumbre que provocan picos pronunciados.




Ilustración 17. Histograma de vix. Elaboración propia.

La Ilustración 18 muestra el histograma de la variable “sofr”, la cual presenta una distribución bimodal, con dos concentraciones principales: una en torno al 0 %, y otra del 5 % (0.05). Estas

corresponden, respectivamente, a un periodo de tipos muy bajo, y a una etapa posterior (2022-2024) en la que la Reserva Federal de Nueva York incrementó gradualmente este índice de referencia. Las frecuencias intermedias reflejan ajustes progresivos realizados durante ese proceso.




Ilustración 18. Histograma de sofr. Elaboración propia.

La Ilustración 19 muestra la serie temporal del precio de cierre del ETF sintético desde enero de 2021 hasta diciembre de 2024, junto con el particionado utilizado para el modelado. Se definieron tres periodos:

- **Entrenamiento (Train):** 2021-01-01 a 2023-06-30 ($\approx 70\%$ de los datos).
- **Validación (Validation):** 2023-07-01 a 2024-03-31 ($\approx 15\%$).
- **Prueba (Test):** 2024-04-01 a 2024-12-31 ($\approx 15\%$).

Esta división mantiene la secuencialidad temporal, evitando fuga de información del futuro hacia el pasado. Se observa una tendencia alcista general del ETF, interrumpida por correcciones intermedias que resultan útiles para evaluar la capacidad de generalización de los modelos.




Ilustración 19. Particiones de entrenamiento, validación y prueba. Elaboración propia.

4.2.1.4.5 Análisis multivariable

Esta sección analiza de forma conjunta las principales variables (precio, *log-returns*, volumen, volatilidad intradía e indicadores técnicos) y los factores macroeconómicos externos (VIX, SOFR),

con el objetivo de entender como interactúan entre sí y que tipo de relaciones, lineales o no lineales mantienen a lo largo del tiempo.

La Ilustración 20 muestra la matriz de correlación de Pearson entre todas las variables numéricas. De su análisis se destacan los siguientes puntos:

- **Altas correlaciones entre precio y medias móviles:** “close” mantiene correlación ≈ 1 con “ema10”, “ema50” y “ema200”, como es esperable al derivarse directamente del precio. Estas relaciones indican que las EMA no aportan información independiente, sino simplemente versión suavizada del cierre.
- **Relaciones estrechas entre indicadores derivados del MACD:** “macd”, “macd_signal” presentan correlaciones muy altas (≈ 0.96 – 0.98), al compartir el mismo cálculo base.
- **Volumen y log del volumen:** Correlación elevada (~ 0.67), coherente con su naturaleza. “log_volume” muestra además una relación algo mayor con la volatilidad, lo que puede resultar útil para el modelado.
- **Variables temporales (hora, día, mes):** Apenas se correlacionan con el resto de variables, lo que indica que el componente temporal puro no explica directamente los movimientos de precio.
- **Variables de volatilidad y riesgo:** “volatility_24h” se correlaciona moderadamente con “log_volume” y ligeramente con el “vix”, lo que muestra que una mayor actividad tiene a incrementarse la volatilidad.
- **Precio y OBV:** Correlación alta (~ 0.95), lo cual tiene sentido, porque el *OBV* acumula volumen según la dirección del cierre.
- **Retornos logarítmicos:** “log_return” y “target_log_return” presentan correlaciones casi nulas con la mayoría de variables, lo que indica la ausencia de una relación lineal directa y justifica el uso de modelos no lineales como LSTM, N-BEATS o TSFEDL para capturar dependencias más complejas.




Ilustración 20. Matriz de correlación entre las variables. Elaboración propia.

Para evitar la multicolinealidad se decidió eliminar variables redundantes que aportaban información duplicada:

- En el caso del volumen, se mantuvo “log_volume” y se descartó “volume”.
- En el caso “close” y “obv”, se mantuvo “close” y se eliminó “obv”
- Para las medias móviles, se conservaron *ema_ratio* y *ema_spread*, que resumen la relación entre medias rápidas y lentas, descartando *ema10*, *ema50*, *ema200*, *macd* y *macd_signal*, por su alta colinealidad entre sí y con el precio de cierre.

La Ilustración 21 muestra un detalle de los retornos logarítmicos horarios (en azul) y la volatilidad móvil de 24 h (en rojo). Se aprecia con claridad cómo los incrementos abruptos de los retornos preceden y acompañan los picos de la volatilidad móvil de 24 horas, confirmando la relación directa entre ambas variables.




Ilustración 21. Detalle de la relación entre log-returns y la volatilidad móvil de 24 horas. Elaboración propia.

4.2.1.4.6 Evolución temporal y contexto macroeconómico

Tras analizar las relaciones entre variables, se muestra la evolución del precio del ETF junto con dos indicadores macroeconómicos (VIX y SOFR) para contextualizar su comportamiento frente a la volatilidad del mercado y la política monetaria.

La Ilustración 22 muestra que los incrementos del SOFR a partir de 2022 y los picos del VIX coinciden con episodios de corrección o alta volatilidad. En cambio, durante 2023-2024, con una volatilidad más baja y una política monetaria estable, el ETF recupera una tendencia alcista.




Ilustración 22. Evolución del precio de cierre, el índice VIX y la tasa SOFR. Elaboración propia.

4.2.1.4.7 Comparación entre conjuntos (train/validation/test)

Para saber qué tan representativos resultaban los *log-returns* de los tres subconjuntos, se emplearon tanto estadísticas descriptivas (véase Tabla 16) como pruebas para comparar la igualdad de sus distribuciones.

Tabla 16. Estadísticos de los conjuntos de entrenamiento, validación y test. Elaboración propia.

Conjunto	Media	Desviación típica	Mediana	Asimetría	Curtosis
train	0.000037	0.002567	0.0	-0.09906	5.2782

validation	0.000077	0.002033	0.0	-0.15287	7.3416
test	0.000045	0.002284	0.0	-0.11262	6.6993

Los resultados de la tabla anterior muestran medias y desviaciones estándar muy cercanas entre *train*, *validation* y *test*, lo que confirma una distribución equilibrada. La asimetría cercana a cero, indica una forma casi simétrica, con una ligera inclinación a la izquierda.

En la prueba ANOVA ($p = 0.5684$) no se hallaron diferencias significativas entre las medias, lo que refuerza la idea que los conjuntos son estadísticamente comparables. En cambio, la prueba de Kolmogorov–Smirnov sí detectó una diferencia notable entre *train* y *validation* ($p = 0.0085$), pero no entre *train–test* ($p = 0.2834$) ni *validation–test* ($p = 0.8357$)

Este resultado sugiere que el punto de corte entre entrenamiento y validación coincide con un cambio de régimen en la serie temporal, lo que puede afectar la calibración y rendimiento de los modelos y explicar posibles variaciones en su rendimiento durante la validación.




Ilustración 23. Distribución de los *log-returns*. Elaboración propia.

En la Ilustración 23 se observa que las distribuciones de *log-returns* para los conjuntos de entrenamiento, validación y prueba presentan un comportamiento muy similar: están centradas en cero, muestran una forma leptocúrtica y poseen colas delgadas. Las diferencias entre conjuntos son sutiles y no se aprecian discrepancias significativas a simple vista.

4.2.1.4.8 Insights y decisiones para el modelado

Para reducir la multicolinealidad y simplificar el modelo, se descartaron variables que, en esencia, contenían información redundante:

- **Volumen:** se conserva “*log_volume*”, que estabiliza la varianza, descartando “*volumen*”.

- **Precio de cierre y OBV:** debido a la alta correlación “close” y el indicador “obv”, se mantiene solo el precio de cierre.
- **Medias móviles e indicadores derivados:** se conservan “ema_ratio” y “ema_spread” por resumir la información de tendencia, eliminando “ema10”, “ema50”, “ema200”, “macd” y “macd_signal”, que son altamente correlacionadas entre sí y con el propio precio

4.2.1.5 Modelado

Tras la preparación de los datos, se diseñaron y entrenaron tres modelos de *deep learning* para predecir los retornos logarítmicos horarios del ETF sintético. La decisión de emplear tres arquitecturas distintas (recurrente, basada en series temporales e híbrida) responde al objetivo de comparar distintos enfoques en su capacidad para captar dependencias temporales y relaciones no lineales propias de las series financieras.

4.2.1.5.1 Configuración General

A continuación, se muestran los principales parámetros comunes del proceso de modelado utilizados en todos los modelos por igual:

- Variable objetivo: “target_log_return”.
- Ventana temporal: secuencias de 64 de pasos. Se utilizó esta ventana temporal por ofrecer un equilibrio entre capturar dependencias a corto y medio plazo y mantener una complejidad computacional manejable.
- Horizonte de predicción: 1 paso (regresión de “log_return”).
- Normalización: *StandardScaler* para las columnas “log_return” y “target_log_return”, y un *MixMaxScaler* propio para cada una de las demás variables.
- División: 70% entrenamiento, 15% validación y 15% test.
- Función de pérdida: Huber Loss, se eligió por su capacidad para equilibrar la precisión del error cuadrático medio (MSE) con la robustez del error absoluto medio (MAE) frente a valores atípicos. Esta función mitiga el efecto de picos repentinos en los *log-returns*, lo que proporciona un entrenamiento más estable.
- Tamaño del lote (*batch_size*): se utilizó un valor de 256 por ofrecer un equilibrio entre estabilidad del aprendizaje y eficiencia computacional. Este valor se determinó tras pruebas preliminares, en las que tamaños menores producían un entrenamiento menos consistente, mientras que tamaños mayores ralentizaban la convergencia y reducían la capacidad de los modelos para adaptarse a patrones locales.

4.2.1.5.2 Preparación de los datos para el modelado

Esta sección describe la preparación técnica de los datos para su uso en los modelos predictivos, incluyendo los pasos de normalización, generación de retardos, estructuración en tensores y división en subconjuntos de entrenamiento, validación y prueba.

Normalización: se aplicó un *StandardScaler* a las variables “log_return” y “target_log_return”, ya que presentan distribuciones centradas en cero y baja varianza, donde este tipo de escalado

preserva su estructura estadística. El resto de características (precios, medias móviles, volumen, etc.) se normalizaron mediante un *MinMaxScaler* independiente por variable, manteniendo sus proporciones originales dentro del rango [0, 1]. Esta combinación equilibra la interpretación económica de los datos con la estabilidad numérica necesaria para el entrenamiento de redes neuronales.

Generación de retardos: para captar la dinámica temporal del mercado, se generaron ventanas de 64 retardos (lags) para cada variable de entrada, equivalentes a cerca de dos jornadas y media de cotización. Este ancho de ventana ofrece contexto suficiente para reconocer patrones de tendencia o volatilidad. La elección de 64 pasos representa un equilibrio entre precisión y eficiencia computacional.

División del dataset: se dividió en tres conjuntos: entrenamiento (70 %), validación (15 %) y prueba (15 %), respetando el orden temporal. El conjunto de entrenamiento se utilizó para ajustar los parámetros del modelo; el de validación, para afinar los hiperparámetros y detectar sobreajuste mediante *early stopping*; y el de prueba, para evaluar la capacidad de generalización sobre datos nunca vistos. Esta distribución es habitual en series temporales y asegura una evaluación fiable.

Generación de tensores de entrada: los datos fueron organizados en tensores tridimensionales de forma (n_muestras, n_retardos, n_variables). Cada secuencia temporal sirve como entrada y la variable “target_log_return” en t+1 es la variable objetivo. Todo el proceso se realizó preservando el orden cronológico (*shuffle = False*) evitando fuga de información.

4.2.1.5.3 Arquitectura de los modelos

Con el objetivo de comparar distintos enfoques de predicción en series temporales financieras, se implementaron tres arquitecturas de redes neuronales con características complementarias: LSTM, N-BEATS y un modelo híbrido TSFEDL.

El código fuente de la configuración de los modelos está disponible en el repositorio previamente citado.

4.2.1.5.3.1 Modelo 1: Long Short-Term Memory (LSTM)

El modelo LSTM se implementó con la biblioteca Keras (TensorFlow), con una arquitectura secuencial orientada a la predicción del “target_log_return”.

Esta arquitectura LSTM incluye dos capas recurrentes de 128 y 64 unidades, donde la primera devuelve secuencias completas para conservar la información temporal. Entre ambas se añade una capa Dropout (0.15) que ayuda a reducir el sobreajuste. Después, una capa densa de 32 neuronas con activación ReLU que permite capturar relaciones no lineales, seguida de una capa de salida con activación lineal encargada de predecir el retorno logarítmico futuro.

El modelo se entrena con el optimizador Adam (learning rate = 0.001) y la función de pérdida Huber, elegida por su equilibrio entre precisión y robustez frente a valores atípicos. Se emplea un tamaño de lote de 256, regularización L2 = 0.001 y 10 épocas de entrenamiento, suficientes para lograr la convergencia sin sobreajuste.

Durante el entrenamiento se aplicaron dos estrategias de control:

- EarlyStopping, para detener el proceso cuando la pérdida de validación deja de mejorar.
- ReduceLROnPlateau, que ajusta automáticamente la tasa de aprendizaje cuando la mejora se estabiliza.

En conjunto, esta configuración permite a la LSTM capturar dependencias temporales a corto y medio plazo, manteniendo un buen equilibrio entre capacidad predictiva, estabilidad y generalización.

4.2.1.5.3.2 *Modelo 2: N-BEATS*

El modelo N-BEATS, en su versión original [22], fue diseñado para la predicción univariante de series temporales. En este trabajo se emplea su variante N-BEATSx disponible en la librería *NeuralForecast* [35], que amplía la arquitectura original para incorporar variables exógenas como entrada. Aun así, la predicción final se mantiene univariante, centrada en el *log-return* horario del ETF sintético.

El modelo se entrenó durante 500 épocas, con una tasa de aprendizaje de 0.001 y un tamaño de lote de 256 muestras. Se utilizó el optimizador AdamW, que incorpora regularización *weight decay* para mejorar la estabilidad y reducir el sobreajuste. Además, se aplicó un dropout = 0.3 como regularización adicional.

El modelo está configurado con dos *stacks* o bloques principales (`stack_types=["identity", "exogenous"]`), lo que permite combinar patrones intrínsecos de la serie con información exógena procedente de otras variables. Cada *stack* contiene una capa MLP con dos niveles ocultos de 128 neuronas (`mlp_units=[[128,128],[128,128]]`), empleando la activación LeakyReLU. La estructura está optimizada para un horizonte de predicción $h=1$, es decir, una predicción unitaria hacia adelante.

Se incluyen todas las variables explicativas seleccionadas (`hist_exog_list=column_names`), que corresponden a las características observadas históricamente, como volumen, medias móviles, indicadores técnicos y otros factores relevantes.

Se utiliza un CSVLogger para almacenar los resultados del entrenamiento (`CSVLogger(save_dir="lightning_logs")`), registrando la evolución de la pérdida y las métricas de validación por época. La evaluación de validación se realiza cada época (`val_check_steps=1`).

4.2.1.5.3.3 *Modelo 3: Híbrido TSFEDL*

El modelo TSFEDL (Time Series Feature Extraction Deep Learning) [36] pertenece a una familia de enfoques híbridos que combinan extracción automática de características con redes neuronales profundas, integrando información estadística, temporal y frecuencial para mejorar la capacidad predictiva.

En este trabajo utiliza la variante Kim-Tae-Young [37], incluida en la librería TSFEDL. Este modelo combina bloques convolucionales (CNN) y recurrentes (LSTM), lo que le permite capturar tanto patrones locales como patrones a largo plazo.

El bloque convolucional detecta estructuras de corto plazo, mientras que el bloque recurrente modela la evolución global de la serie. Finalmente, un bloque denso totalmente conectado genera la predicción del retorno logarítmico.

El modelo Kim-Tae-Young destaca por equilibrar la sensibilidad a los cambios abruptos con la estabilidad en tendencias a largo plazo.

El modelo se entrenó durante 50 épocas con una tasa de aprendizaje de 0.00005, un valor bajo que favorece una convergencia estable dada la complejidad de la arquitectura y el ruido propio de los retornos horarios. Como en el resto de modelos, se utilizó un batch size de 256 y la función de pérdida Huber Loss.

El tensor de entrada tiene la forma $(n_lags, n_features)$, generada a partir de una ventana temporal deslizante. Sobre este se instancia el modelo base TSFEDL KimTaeYoung, configurado con `include_top=False` para añadir un cabezal de regresión personalizado, compuesto por:

- una capa *Flatten*, que convierte los mapas de características en un vector.
- una capa densa de 128 neuronas ReLU para combinar patrones no lineales.
- una capa *Dropout* del 20 % para mitigar el sobreajuste.
- y una capa de salida lineal con una única neurona, encargada de predecir el retorno logarítmico futuro.

Esta arquitectura combina la capacidad de las CNN para detectar patrones locales con la de las redes recurrentes para modelar dependencias temporales, logrando capturar de forma más precisa la dinámica de corto y largo plazo de las series financieras.

4.2.1.5.4 Entrenamiento

Modelo LSTM: en la Ilustración 24 puede apreciarse la evolución de la pérdida de entrenamiento y validación a lo largo de las épocas. La curva de validación alcanza una meseta, a partir del cual el modelo deja de mejorar de manera significativa.




Ilustración 24. Función de pérdida durante entrenamiento y validación para LSTM. Elaboración propia.

Los hiperparámetros se ajustaron mediante una búsqueda exploratoria manual (*manual tuning*), probando iterativamente distintas combinaciones y midiendo el rendimiento en el conjunto de validación. Dada la limitación de recursos computacionales, se optó por una búsqueda manual en lugar de métodos automáticos de optimización.

Modelo N-BEATS: en la Ilustración 25 puede apreciarse la evolución de la pérdida de entrenamiento y validación a lo largo de las épocas. La curva de pérdida de entrenamiento baja de forma sostenida durante las primeras épocas, para a continuación estabilizarse con ligeras oscilaciones, lo que indica que el modelo continúa ajustando los parámetros. La pérdida de validación, en cambio, desciende de forma más suave y alcanza una meseta estable a partir de aproximadamente la época 200, manteniéndose por debajo de la pérdida de entrenamiento. Esta diferencia sugiere que el modelo ha logrado una buena generalización sobre los datos de validación, sin evidencias de sobreajuste. La mayor variabilidad del *train loss* puede atribuirse a la naturaleza estocástica del optimizador AdamW y al uso de *mini-batches* durante el aprendizaje. En conjunto, la gráfica refleja un entrenamiento estable y convergente, donde el modelo consigue minimizar la pérdida sin degradar su rendimiento sobre el conjunto de validación.



Ilustración 25. Función de pérdida durante entrenamiento y validación N-BEATS. Elaboración propia.

Modelo TSFEDL: en la Ilustración 26 se muestra la evolución de la función de pérdida durante el entrenamiento y la validación del modelo. La curva azul representa la pérdida sobre el conjunto de entrenamiento, mientras que la curva naranja corresponde al conjunto de validación.

Ambas curvas muestran una clara inclinación descendente, indicando que el modelo fue capaz de reducir progresivamente el error a medida que avanzaban las épocas. La pérdida de validación sigue una trayectoria similar a la de entrenamiento, sin incrementos abruptos ni divergencias significativas, lo cual sugiere una buena generalización y la ausencia de sobreajuste en las primeras etapas del entrenamiento.

Las diferencias entre ambas curvas se mantienen estables y de magnitud reducida, lo que refuerza la idea de que el modelo ha aprendido sin memorizar los patrones específicos del conjunto de entrenamiento.

En conjunto, la gráfica demuestra que el proceso de entrenamiento fue estable y controlado, alcanzando un equilibrio adecuado entre ajuste y capacidad de generalización.




Ilustración 26. Función de pérdida durante entrenamiento y validación para TSFEDL. Elaboración propia.

4.2.1.5.5 Estructura de experimentación

Los experimentos se desarrollaron en Python 3.12.7, un lenguaje muy utilizado en investigación científica y *machine learning* por su ecosistema de librerías especializadas.

Se emplearon TensorFlow y Keras para construir y entrenar la red LSTM, NeuralForecast para implementar el modelo N-BEATS, y TSFEDL y Keras para los modelos híbridos CNN–RNN predefinidos.

El entorno se configuró en Windows 11 Pro utilizando *venv* para el control de dependencias, asegurando una instalación aislada y reproducible. El uso de GPU permitió acelerar significativamente el entrenamiento y los tiempos de predicción de los modelos.

El proyecto se gestionó con Git y se alojó en un repositorio privado de GitHub, lo que garantizó el control de versiones, la trazabilidad de los cambios y la documentación completa del flujo de trabajo mediante *notebooks* y scripts de Python. Esta práctica asegura la mantenibilidad del código y facilita la replicación de los experimentos.

Para garantizar la reproducibilidad, se fijaron semillas aleatorias en todas las librerías relevantes (*numpy*, *random*, *tensorflow* y *torch*), además de activar configuraciones deterministas en GPU. Con ello se evitó la variabilidad no controlada en la inicialización de pesos o en los algoritmos de optimización, asegurando resultados consistentes entre ejecuciones.

4.2.1.6 Evaluación

La fase de evaluación constituye un paso esencial dentro de la metodología CRISP-DM, pues permite verificar si los modelos desarrollados cumplen los objetivos planteados. Tras la preparación de los datos y la implementación de las distintas arquitecturas, esta etapa se centra en analizar su rendimiento y en comprobar si las predicciones obtenidas son consistentes y útiles en el contexto de la renta variable y el trading algorítmico.

En este capítulo se presentan los resultados de los modelos principales y se comparan con tres modelos *baseline*: *Distributed Random predictor*, *Mean predictor* y *Zero predictor*. Estos modelos sencillos actúan como punto de partida para evaluar de forma más clara el valor añadido de las arquitecturas de *deep learning*.

La evaluación va más allá de la precisión estadística, considerando también la estabilidad temporal, la capacidad de generalización ante datos no vistos y la utilidad práctica de las predicciones. Este análisis conjunto permite no solo identificar el modelo con mejor desempeño, sino también comprender sus fortalezas y limitaciones en relación con los objetivos del proyecto.

4.2.1.6.1 Objetivos de la evaluación

La fase de evaluación busca determinar hasta qué punto los modelos desarrollados cumplen los objetivos del trabajo y valorar su aplicabilidad en la predicción de *log-returns*. Más que identificar el modelo con menor error, se pretende realizar un análisis que combine precisión estadística, capacidad de generalización y utilidad práctica.

Los objetivos de esta fase son:

1. Medir el rendimiento predictivo de los modelos LSTM, N-BEATS y TSFEDL mediante métricas como RMSE, MSE, MAE y R^2 .
2. Evaluar la capacidad direccional de los modelos, es decir, su acierto al anticipar el movimiento del activo, a través de la *directional accuracy*.
3. Analizar la eficiencia computacional, considerando los tiempos de entrenamiento y predicción.
4. Comparar los resultados con modelos *baseline* para establecer un punto mínimo de referencia.
5. Examinar la estabilidad y robustez de los modelos en los conjuntos de entrenamiento, validación y prueba, detectando posibles casos de *overfitting* o *underfitting*.
6. Evaluar la aplicabilidad práctica de las predicciones en contextos financieros simulados, mediante indicadores adicionales como el ratio de Sharpe estimado.

En conjunto, esta evaluación permite valorar no solo la calidad técnica de los modelos, sino también su relevancia práctica en el mercado, ofreciendo una visión completa de sus fortalezas y limitaciones.

4.2.1.6.2 Modelos baseline

Para interpretar correctamente el rendimiento de las arquitecturas propuestas, es necesario disponer de modelos de referencia que actúen como punto de comparación. Estos modelos *baseline* no buscan ofrecer predicciones precisas, sino establecer un umbral mínimo de rendimiento, que permita evaluar si las arquitecturas avanzadas realmente aportan una mejora significativa frente a enfoques simples.

En este trabajo se han definido tres modelos *baseline*:

1. **Distribution Random predictor:** produce predicciones aleatorias siguiendo la distribución empírica de las direcciones (subida, neutro, bajada) observadas en el conjunto de entrenamiento. De este modo, evita el sesgo del predictor aleatorio uniforme ante clases desbalanceadas.
2. **Mean predictor:** asigna como predicción **la media histórica** de los *log-returns* del conjunto de entrenamiento. Aunque simple, sirve para contrastar el desempeño frente a un modelo estático que ignora la dinámica temporal.
3. **Zero predictor:** predice siempre un retorno igual a **cero**. Aunque simple, sirve para contrastar el desempeño frente a un modelo estático que ignora la dinámica temporal

La comparación con estos modelos permite contextualizar los resultados obtenidos por las arquitecturas LSTM, N-BEATS y TSFEDL. En particular, si los modelos complejos no logran mejorar de forma consistente a estas aproximaciones básicas, su valor práctico en entornos financieros quedaría cuestionado.

4.2.1.6.3 Métricas de rendimiento

Para evaluar el rendimiento de los modelos, se emplearon métricas que permiten medir tanto la precisión numérica de las predicciones como su relevancia práctica en el contexto del trading algorítmico.

1. Métricas de error y ajuste

- MSE (Mean Squared Error) y RMSE (Root Mean Squared Error): penalizan más los errores grandes y miden la desviación media cuadrática entre valores reales y predichos.
- MAE (Mean Absolute Error): mide el error medio absoluto, más robusto frente a valores atípicos.
- R^2 (Coeficiente de determinación): cuantifica la proporción de la variabilidad de los valores reales que el modelo es capaz de explicar mediante sus predicciones.

Estas métricas evalúan la capacidad general de ajuste del modelo y son estándar en problemas de regresión.

2. Métrica de precisión direccional

Se utilizó la Directional Accuracy (DA) para evaluar la capacidad del modelo de anticipar correctamente la dirección de los movimientos. La clasificación se basa en tres categorías (*up*,

neutral y *down*) definidas mediante un método de cuartiles ajustado con un umbral de ± 0.0001 , que evita el desequilibrio de clases. Esta regla generó una distribución de clases de 22.9% *up*, 55.9% *neutral* y 21.1% *down*, en el conjunto de entrenamiento.

El valor del umbral 0.0001 se estableció tras un proceso de prueba y error manual, buscando un punto de equilibrio que permitiera diferenciar cambios significativos en los *log-returns* sin considerar como movimientos relevantes las pequeñas oscilaciones propias del ruido del mercado, teniendo en cuenta que la desviación estándar del conjunto de entrenamiento es de 0.002567.

3. Métrica financiera: Ratio de Sharpe simulado

Para evaluar la utilidad práctica de las predicciones, se calculó un Sharpe ratio simulado a partir de una estrategia teórica *long/short*. El modelo asume posiciones largas o cortas según el signo del retorno predicho y neutras en el rango $\pm \delta$. Este indicador mide la rentabilidad ajustada al riesgo, de modo que valores altos reflejan estrategias estables y consistentes, mientras que valores cercanos a cero o negativos indican señales poco informativas.

4. Métricas computacionales

Para valorar la eficiencia temporal y viabilidad operativa, se registraron los tiempos de entrenamiento y predicción, medidos en segundos mediante funciones *time.time()* de Python, bajo condiciones de hardware constantes. Estas métricas permiten comparar el coste computacional de cada arquitectura y su adecuación a entornos de predicción en tiempo real.

Las fórmulas completas las métricas se incluyen en el Apéndice A

4.2.1.6.4 Resultados por modelos

En esta sección se presentan los resultados obtenidos por los modelos desarrollados (LSTM, N-BEATS y TSFEDL) comparándolos con los modelos *baseline*. El objetivo es evaluar su rendimiento desde tres perspectivas complementarias:

1. Precisión numérica, mediante métricas de error y ajuste
2. Capacidad de predicción direccional, analizando la habilidad del modelo de anticipar el sentido de los movimientos del mercado.
3. Utilidad práctica en el contexto de *trading algorítmico*, utilizando medidas como el ratio de Sharpe simulado y la eficiencia computacional.

Para cada modelo se presentan las métricas calculadas en el conjunto de prueba, junto con gráficos que muestran la evolución de las predicciones frente a los valores reales.

4.2.1.6.4.1 Modelos base

4.2.1.6.4.1.1 Distribution Random predictor

Este modelo base genera predicciones de *log-return* de forma aleatoria, manteniendo la misma distribución empírica de direcciones (alcista, neutra y bajista) observada en el conjunto de entrenamiento.

Para su construcción, se utilizó la misma metodología descrita en la sección “Direction Accuracy”, aplicando la función de clasificación direccional sobre todos los registros del conjunto de entrenamiento. A partir de ello se obtuvieron las siguientes proporciones:

$$P(d_t = 1) = 0.229, P(d_t = 0) = 0.559, P(d_t = -1) = 0.211$$

Estas probabilidades se utilizaron como distribución de muestreo para generar las predicciones aleatorias. En lugar de estimar valores de magnitud variable, se fijó $x = 1$, de manera que el modelo únicamente simula la dirección del movimiento sin intentar reproducir su intensidad. De esta forma, el Distribution Random Predictor representa un proceso estocástico coherente con la estructura direccional del activo, pero carente de información temporal o contextual.

Este modelo actúa como *baseline* estocástico, estableciendo un límite inferior de rendimiento condicionado a la distribución real de las direcciones observadas. Su objetivo no es predecir, sino servir como referencia para determinar si los modelos neuronales son capaces de superar el comportamiento del azar.

Los resultados se resumen en la Tabla 17:

Tabla 17. Métricas del modelo Distribution Random. Elaboración propia.

Modelo	MSE	RMSE	MAE	R2	Direction	Sharpe
Distribution random	0.0000082	0.002873	0.001933	-0.5831	40.79	-0.0147

La Ilustración 27 muestra un detalle del conjunto de prueba de los *log-returns*. Como era de esperar, las predicciones (en negro) presentan un comportamiento puramente aleatorio, oscilando alrededor de cero sin seguir la dirección ni la magnitud de los valores reales. Este patrón coincide con las métricas ($R^2 \approx -0.56$, *directional accuracy* $\approx 41.59\%$), que confirman la ausencia total de poder predictivo.

La Ilustración 28 muestra como la reconstrucción acumulada del precio produce una trayectoria descendente sin relación con la tendencia real, validando así su papel como referencia mínima de rendimiento frente a la cual se compararán los modelos de aprendizaje profundo.




Ilustración 27. Evolución de log-returns del modelo *Distribution Random*, para el conjunto de prueba. Elaboración propia.




Ilustración 28. Evolución precios del modelo *Distribution Random*. Elaboración propia.

Las fórmulas completas se incluyen en el Apéndice A.

4.2.1.6.4.1.2 Mean predictor

El *Mean Predictor* toma como predicción el valor medio de los log-returns del conjunto de entrenamiento:

$$\hat{y}_t = \bar{y}_{train}$$

Donde $\hat{y}_t$ es la predicción del modelo para el instante t y $\bar{y}_{train}$ representa la media de los log_return del conjunto de entrenamiento (0.00049798).

Este modelo evalúa la capacidad de los modelos avanzados para mejorar una predicción promedio constante. Los resultados se resumen en la Tabla 18:

Tabla 18. Métricas del modelo Mean. Elaboración propia.

Modelo	MSE	RMSE	MAE	R2	Direction	Sharpe
baseline_mean	0.0000052	0.002283	0.001090	-0.000008070	56.75	NaN

La Ilustración 29 muestra un detalle del conjunto de prueba de los log-returns. Las predicciones (en negro) permanecen constantes alrededor de cero, reflejando el valor medio del conjunto de entrenamiento y generando una línea estable sin variaciones temporales.

En la Ilustración 30, la reconstrucción acumulada del precio produce una curva suavemente ascendente, consecuencia de la integración de un retorno medio positivo. Aunque el modelo obtiene un error bajo ($MSE \approx 5 \times 10^{-6}$) y una precisión direccional moderada ($\approx 57\%$), su aparente rendimiento se explica por la estructura estadística de los datos (el 57% de direcciones son neutras) más que por una capacidad predictiva real. Por ello, el *Mean Predictor* se considera una referencia determinista mínima frente a la cual evaluar la mejora de los modelos neuronales.




Ilustración 29. Evolución de log-returns del modelo Mean, para el conjunto de prueba. Elaboración propia.




Ilustración 30. Evolución precios del modelo Mean. Elaboración propia.

4.2.1.6.4.1.3 Zero predictor

El *Zero Predictor* asume que los retornos futuros serán nulos y predice siempre un log-return igual a cero:

$$\hat{y}_t = 0$$

donde $\hat{y}_t$ representa la predicción del modelo para el instante t.

Este modelo representa un sistema que no anticipa movimientos de mercado. Los resultados se resumen en la Tabla 19:

Tabla 19. Métricas del modelo Zero. Elaboración propia.

Modelo	MSE	RMSE	MAE	R2	Direction	Sharpe
baseline_zero	0.0000052	0.002284	0.001070	-0.000394	56.75	NaN

La Ilustración 31 muestra un detalle del conjunto de prueba de los log-returns. Se observa que las predicciones (en negro) permanecen constantes en cero durante todo el periodo, reflejando un modelo que asume la ausencia completa de variación. Esta constancia genera una línea horizontal sin correlación con los valores reales.

En la Ilustración 32, la reconstrucción acumulada del precio produce una trayectoria completamente plana a partir del punto de predicción, sin tendencia alguna. Aunque el error medio es bajo ($MSE \approx 5 \times 10^{-6}$) y la precisión direccional alcanza el 56.75 %, estos resultados se deben a la estructura estadística del dataset (igual que con el mean predictor) y no a una capacidad predictiva real. Por ello, el *Zero Predictor* constituye la referencia más simple y determinista dentro del conjunto de modelos *baseline*, útil únicamente como límite inferior de comparación para los modelos neuronales.




Ilustración 31. Evolución de log-returns del modelo Zero, para el conjunto de prueba. Elaboración propia.




Ilustración 32. Evolución precios del modelo Zero. Elaboración propia.

4.2.1.6.4.1.4 Resumen visual de las predicciones de los modelos base

La Ilustración 33 muestra la evolución del precio acumulado reconstruido a partir de las predicciones de los tres modelos *baseline* junto con la serie real del ETF en los conjuntos de entrenamiento, validación y test.

Los resultados confirman que estos enfoques no son predictivos. El modelo Distribution Random genera trayectorias caóticas, ajenas al comportamiento real del ETF, evidenciando su naturaleza estocástica. Por otro lado, los modelos Mean y Zero, apenas varían, produciendo líneas prácticamente planas o con pendiente constante, reflejando una incapacidad para capturar las fluctuaciones del mercado.

En conjunto, el gráfico evidencia que los modelos *baseline* no logran reproducir ni la dinámica ni la tendencia del activo. Su única función es actuar como una referencia mínima frente a las cuales evaluar la mejora aportada por las arquitecturas avanzadas.




Ilustración 33. Evolución de precio y predicciones acumuladas de los modelos baseline. Elaboración propia.

4.2.1.6.4.1.5 Resumen cuantitativo de métricas de los modelos base

La Tabla X resume las métricas obtenidas por los modelos *baseline* sobre el conjunto de prueba. Estos resultados sirven como referencia mínima para evaluar la capacidad predictiva de las arquitecturas neuronales desarrolladas posteriormente. Se incluyen métricas de error (MSE, RMSE, MAE), de ajuste (R^2), de rendimiento direccional y rendimiento financiero (ratio de Sharpe simulado).

Tabla 20. Métricas de los modelos baseline. Elaboración propia.

Modelo	MSE	RMSE	MAE	R2	Dirección(%)	Sharpe
Distribution Random	0.0000082	0.002873	0.001933	-0.5831	40.79	-0.0147
Mean	0.0000052	0.002283	0.001090	-0.000008	56.75	NaN
Zero	0.0000052	0.002284	0.001070	-0.000394	56.75	NaN

Los resultados de la Tabla 20 muestran claras diferencias entre los enfoques aleatorios (random) y los triviales deterministas (Mean y Zero):

1. El modelo Distribution Random

- Presenta errores más altos ($MSE \approx 0.000008$) y de RMSE en torno a 0.0029, claramente superiores a los de los modelos deterministas. Y un valor de R^2 negativo (-0.5831), lo que confirma que no explica ninguna varianza del valor real.
- La precisión direccional se sitúa en un 40.79 %, en línea con un comportamiento aleatorio, y el ratio de Sharpe es negativo, y prácticamente nulo, evidenciando ausencia total de rentabilidad ajustada al riesgo

2. Modelos triviales (Mean y Zero Predictors)

- Alcanzan los errores más bajos del conjunto ($MSE \approx 5 \times 10^{-6}$; $RMSE \approx 0.00228$), resultado de su comportamiento estable y centrado en valores constantes. Los coeficientes R^2 son cercanos a cero, indicando que no aportan información predictiva.
- Su precisión direccional ($\approx 56.75\%$) refleja la ligera asimetría estadística de los datos, más que una capacidad de predicción real. El ratio de Sharpe no es aplicable, al no generar señales con variabilidad.

En conjunto, los resultados confirman que los modelos *baseline* carecen de poder predictivo, con R^2 negativos o nulos y ratios de Sharpe insignificantes.

Sin embargo, los modelos Mean y Zero logran errores menores y una precisión direccional algo superior, por lo que se consideran las referencias deterministas mínimas que los modelos neuronales deberán superar en las secciones siguientes.

4.2.1.6.4.2 Modelos principales

4.2.1.6.4.2.1 LSTM

La Tabla 21 resume las métricas obtenidas por el modelo LSTM sobre el conjunto de prueba.

Tabla 21. Métricas del modelo LSTM. Elaboración propia.

Modelo	MSE	RMSE	MAE	R^2	Direction	Sharpe
LSTM	0.0000052	0.002282	0.00108	0.00127	60.65	0.026

La Ilustración 34 muestra la comparación entre los *log-returns* reales y predichos en el conjunto de prueba. Se observa que las predicciones siguen la dinámica general de la serie real, reproduciendo levemente los picos y caídas más significativos, aunque con bastante atenuación en la magnitud de los movimientos, cosa de difícil apreciación en este tipo de gráficos.




Ilustración 34. Evolución de log-returns del modelo LSTM, para el conjunto de prueba. Elaboración propia.




Ilustración 35. Evolución precios del modelo LSTM. Elaboración propia.

La Ilustración 35 muestra que el modelo predice la tendencia ascendente global del precio, lo que indica que el modelo captura correctamente la tendencia alcista a lo largo del tiempo. Aunque sigue bien la tendencia, no replica con precisión las oscilaciones locales, lo que es consistente con lo hecho que el modelo tiende a suavizar los *log-returns*.

4.2.1.6.4.2.2 N-BEATS

La Tabla 22 resume las métricas obtenidas por el modelo N-BEATS sobre el conjunto de prueba.

Tabla 22. Métricas del modelo N-BEATS. Elaboración propia.

Modelo	MSE	RMSE	MAE	R ²	Dirección(%)	Sharpe
N-BEATS	0.0000056	0.002387	0.001188	-0.0927	67.47	0.054

La Ilustración 36 muestra la comparación entre los *log-returns* reales y predichos del conjunto de prueba. Se observa que las predicciones del modelo (línea negra) reproducen con buena precisión la estructura general de los *log-returns* reales. Aunque no logra seguir cada oscilación puntual, el modelo consigue mantener la coherencia temporal de los movimientos. Se aprecia una ligera atenuación en la amplitud de las predicciones.




Ilustración 36. Evolución de *log-returns* del modelo N-BEATS, para el conjunto de prueba. Elaboración propia.




Ilustración 37. Evolución de precios del modelo N-BEATS. Elaboración propia.

En la Ilustración 37 se observa como la serie de precios reconstruida a partir de los *log-returns* predichos muestra una trayectoria acumulada muy próxima a la evolución real del ETF sintético, manteniendo la dirección y pendiente general del precio. El modelo reproduce con notable fidelidad los cambios locales, tanto en validación como en *test*, evidenciando su capacidad para generalizar patrones aprendidos en el entrenamiento.

4.2.1.6.4.2.3 TSFEDL

La Tabla 23 resume las métricas obtenidas por el modelo TSFEDL sobre el conjunto de prueba.

Tabla 23. Métricas del modelo TSFEDL. Elaboración propia.

Modelo	MSE	RMSE	MAE	R ²	Direction	Sharpe
TSFEDL	0.0000052	0.002282	0.001095	0.00077	60.27	0.030

La Ilustración 38 muestra la comparación entre los *log-returns* reales y predichos en el conjunto de prueba. Se observa, que las predicciones presentan coherencia con los valores reales, pero a con una magnitud mucho más suavizada.




Ilustración 38. Evolución de log-returns del modelo TSFEDL, para el conjunto de prueba. Elaboración propia.




Ilustración 39. Evolución de precios del modelo TSFEDL. Elaboración propia.

En la Ilustración 39 la serie acumulada del precio predicho (línea negra) muestra un seguimiento muy próximo al precio real del ETF sintético. El modelo logra predecir la tendencia alcista general con gran precisión, manteniendo cierta coherencia con los puntos de inflexión más importantes. En el conjunto de prueba se observa una desviación creciente pero moderada entre el precio real y el predicho. En general se detecta cierta capacidad de predecir movimientos bruscos locales, aunque de una forma muy suavizada.

4.2.1.6.4.2.4 Resumen visual de las predicciones de los modelos

La Ilustración 40 compara los *log-returns* reales (en verde) con las predicciones generadas por los modelos LSTM, N-BEATS y TSFEDL durante el periodo de prueba. Se observa que los tres modelos siguen la dinámica general de los *log-returns reales*, reproduciendo adecuadamente las fluctuaciones direccionales del mercado.

El modelo N-BEATS muestra mayor capacidad para capturar valores extremos, mientras que LSTM y TSFEDL ofrecen predicciones más suaves y conservadoras.

En conjunto, la figura confirma que las tres arquitecturas captan la dirección general de los movimientos, aunque su capacidad para replicar la magnitud exacta es limitada, un comportamiento habitual en la predicción de *log-returns* financieros debido al elevado ruido y la baja relación señal-ruido de este tipo de datos.




Ilustración 40. Comparación entre los log-returns reales y las predicciones. Elaboración propia.

La Ilustración 41 presenta la evolución del precio acumulado reconstruido a partir de las predicciones de los tres modelos principales, junto con la serie real en los conjuntos de entrenamiento, validación y test.

Los tres modelos reproducen correctamente la tendencia general del ETF, aunque con diferentes grados de precisión.

El LSTM logra ajustarse a la tendencia real, tanto en validación como en *test*. Sus predicciones se mantienen cerca del precio real, aunque sin captar los movimientos locales. Esto indica que ha sido capaz de realizar un buen aprendizaje de la dirección y magnitud de los *log-returns*.

El N-BEATS sigue mejor las oscilaciones de corto plazo, mostrando una buena sensibilidad ante cambios rápidos del mercado. A pesar de ello, presenta una desviación creciente respecto al precio real a largo plazo.

El TSFEDL ofrece la trayectoria más fiel al comportamiento real, con más capacidad de predicción de movimientos locales que la LSTM, pero menos que la N-BEATS. Se observa también, una leve subestimación hacia el final del periodo de prueba.




Ilustración 41. Evolución precios y predicciones acumuladas de los modelos. Elaboración propia.

Como es común en modelos acumulativos, los errores pequeños en *log-returns* se amplifican al reconstruir el precio. Esto se ve con claridad en el tramo final, donde las diferencias entre los modelos se hacen más visibles, en especial en los modelos N-BEATS y TSFEDL.

4.2.1.6.4.2.5 Resumen cuantitativo de métricas de los modelos

La Tabla 24 resume las métricas obtenidas por los tres modelos principales en el conjunto de prueba.

Tabla 24. Métricas de los modelos. Elaboración propia.

Modelo	MSE	RMSE	MAE	R ²	Dirección(%)	Sharpe
LSTM	0.0000052	0.002282	0.001080	0.00127	60.65	0.026
NBEATS	0.0000056	0.002387	0.001188	-0.0927	67.47	0.054
TSFEDL	0.0000052	0.002282	0.001095	0.00077	60.27	0.030

La tabla anterior muestra las métricas obtenidas por los tres modelos principales evaluados en el conjunto de prueba. En general, los tres modelos presentan valores de error próximos entre sí ($MSE \approx 0.000005$, $RMSE \approx 0.0023$, $MAE \approx 0.0011$), lo que indica una capacidad de ajuste similar a nivel global. Sin embargo, se observan diferencias importantes en las métricas de dirección, y de ratio de Sharpe simulado.

El LSTM alcanza el mejor R^2 (0.00127) y una direccionalidad moderada (60.65%), mostrando un equilibrio entre ajuste y capacidad direccional, aunque con un Sharpe ratio más bajo (0.026).

El N-BEATS alcanza la mayor precisión direccional (67.47 %) y el ratio de Sharpe más alta (0.054), lo que indica una mejor capacidad de predicción. No obstante, su coeficiente de determinación negativo ($R^2 = -0.0927$) implica que, aunque acierta con la dirección de los movimientos, no explica de forma óptima la variabilidad de los *log-returns*.

El TSFEDL presenta la peor precisión direccional (60.27 %), pero un R^2 positivo (0.00077) y superior al de N-BEATS, lo que refleja una buena coherencia general con la tendencia del activo, aunque con menor sensibilidad a los movimientos bruscos.

Los valores bajos o negativos de R^2 son esperables en series financieras altamente volátiles, donde el ruido domina la señal. Por ello, la dirección de aciertos y el ratio de Sharpe se consideran métricas más representativas. En este sentido, aunque los tres modelos presentan ratios de Sharpe modestos (0.02–0.05), su signo positivo confirma que logran generar predicciones algo más consistentes que el azar, especialmente el modelo N-BEATS.

4.2.1.6.4.3 Comparativa de eficiencia computacional de los modelos

Este apartado analiza la eficiencia computacional de los tres modelos principales, considerando los tiempos de entrenamiento y predicción, el número de parámetros, el tamaño del modelo y el dispositivo utilizado. Estos indicadores permiten evaluar tanto la complejidad técnica de cada arquitectura como su viabilidad práctica, un aspecto fundamental en entornos de *trading* algorítmico donde la latencia y la rapidez de ejecución son factores críticos.

Tabla 25. Métricas de rendimiento computacional y complejidad. Elaboración propia.

Modelo	Tiempo de entrenamiento(s)	Tiempo de predicción (s)	Numero de parámetros	Tamaño del modelo (MB)	Dispositivo
LSTM	154.8	2.6	125 249	0.48	GPU
NBEATS	26.6	18.6	345 000	1.32	GPU
TSFEDL	210.0	1.1	51 713	0.20	GPU

Las métricas de la Tabla 25 reflejan diferencias notables en el rendimiento computacional. N-BEATS es el modelo más rápido de entrenar, aunque su tiempo de inferencia es mayor debido a su estructura completamente conectada. LSTM logra un equilibrio razonable entre tiempo,

tamaño y precisión, mientras que TSFEDL, pese a requerir más tiempo de entrenamiento, obtiene la latencia más baja y el tamaño más reducido, siendo la opción más eficiente para escenarios de predicción en tiempo real.

4.2.1.6.5 Estabilidad de los modelos

Para evaluar la estabilidad de los modelos, se aplicó una prueba ANOVA de una vía sobre los errores simples de predicción obtenidos en los conjuntos de entrenamiento, validación y test, definidos como:

$$e_t = y_t - \hat{y}_t$$

donde e_t es el error simple en el instante t , y_t es el valor real en el instante t , y $\hat{y}_t$ es el valor predicho en el instante t

Esta prueba permite determinar si las diferencias entre conjuntos son estadísticamente significativas o si los modelos mantienen un comportamiento consistente frente a datos no vistos.

La Tabla 26 muestra los resultados de la prueba ANOVA aplicado a los errores de predicción simples de los tres modelos principales.

Tabla 26. Métricas de estabilidad. Elaboración propia.

Modelo	F-statistic	p-value	Comentario
LSTM	3.168	0.042	Estabilidad reducida
NBEATS	0.191	0.825	Estable
TSFEDL	0.960	0.382	Estabilidad moderada

Los resultados ponen de manifiesto diferencias notables en el grado de estabilidad entre los diferentes modelos.

El LSTM presenta un p-value menor a 0.05, lo que indica diferencias estadísticamente significativas entre conjuntos y, por tanto, una estabilidad reducida.

El N-BEATS, con un p-value de 0.825, muestra la conducta más estable.

El TSFEDL, con p-value de 0.382, indica una estabilidad moderada, sin diferencias significativas, pero con mayor variabilidad que N-BEATS.

El análisis confirma que el N-BEATS es el modelo más estable, seguido por TSFEDL siguiéndole de cerca, mientras que el LSTM muestra una menor estabilidad.

4.2.1.6.6 Conclusión parcial

El análisis de los tres modelos revela diferencias claras en su comportamiento y rendimiento. En general, todos reproducen de forma coherente la tendencia global del ETF, aunque con distinto grado de precisión.

El **N-BEATS** es el más sensible a los movimientos de corto plazo, con la mayor precisión direccional y una mejor ratio de Sharpe, aunque presenta un R^2 ligeramente negativo. Muestra el comportamiento más estable de entre todos los modelos.

El **LSTM** muestra un comportamiento estable reproduciendo la tendencia alcista. Sin embargo, la suavidad de la curva proyectada indica que el modelo tiende a suavizar las oscilaciones y a subestimar la volatilidad a corto plazo, lo que sugiere un enfoque más orientado a capturar la dirección global del mercado que a anticipar los movimientos bruscos o repentinos.

El **TSFEDL** reproduce de forma coherente la tendencia alcista general del activo, aunque pierde precisión en la fase final al mostrar una ligera desviación y una menor sensibilidad frente a las fluctuaciones reales del mercado.

Dado que el objetivo del trabajo es la especulación, el modelo N-BEATS se posiciona como la opción más adecuada, al ofrecer la mejor precisión direccional, un ratio de Sharpe superior y una mayor estabilidad en sus predicciones.

4.2.1.6.7 Comparación y discusión

Este apartado analiza de forma comparativa el rendimiento de los tres modelos principales a partir de las métricas, la estabilidad y las predicciones visuales, con el fin de identificar cuál ofrece el mejor equilibrio entre precisión, robustez, capacidad direccional y desempeño financiero.

Los tres modelos basados en redes neuronales superan ampliamente los modelos *baseline*, en todas las métricas evaluadas. Esto se debe a su capacidad para aprender dependencias temporales y relaciones no lineales presentes en las series de *log-returns*, mientras que los *baseline* se limitan a estimaciones estáticas o aleatorias sin estructura temporal.

A nivel cuantitativo, los tres modelos presentan errores muy similares ($MSE \approx 5 \times 10^{-6}$), pero difieren en el resto de métricas. El N-BEATS destaca en desempeño financiero, con el mayor porcentaje de acierto direccional (67.47%) y el mayor Sharpe ratio (0.054), lo que indica una mejor capacidad para anticipar correctamente la dirección del mercado y generar señales más rentables ajustadas al riesgo. En contraste, LSTM y TSFEDL, aunque similares en estabilidad direccional (~60%), presentan mejores valores de R^2 , con LSTM ligeramente por delante ($R^2 = 0.00127$ frente a 0.00077), lo que sugiere una mayor coherencia con la varianza de los datos reales. TSFEDL, en particular, se posiciona como un modelo intermedio, logrando un equilibrio entre ajuste estadístico y desempeño.

A nivel cualitativo y visual, se observa que cada uno presenta fortalezas diferenciadas según el horizonte temporal del pronóstico:

- **LSTM** muestra un excelente ajuste a la tendencia de largo plazo, capturando la dirección general del precio acumulado con alta precisión. Sin embargo, su respuesta a movimientos bruscos o locales es limitada, debido a la atenuación inherente al modelo.
- **NBEATS**, en cambio, responde mejor a variaciones de corto plazo, siendo más sensible a movimientos locales y cambios de dirección, lo cual se refleja en su mayor precisión direccional. No obstante, esta sensibilidad también conlleva una mayor desviación acumulativa en el largo plazo.
- **TSFEDL** se sitúa en un punto intermedio, ofreciendo un balance entre la estabilidad de LSTM y la sensibilidad de NBEATS, lo que lo convierte en una alternativa robusta para aplicaciones donde se requiera buena respuesta tanto a corto como a largo plazo.

A nivel de estabilidad, el análisis ANOVA evidencia que N-BEATS es el modelo más estable, seguido de TSFEDL, mientras que LSTM muestra mayor variabilidad entre conjuntos de datos. Esto sugiere que N-BEATS generaliza mejor frente a cambios en la estructura temporal del mercado.

En cuanto a la sensibilidad a los hiperparámetros, LSTM resultó ser el modelo más sensible a el tamaño de ventana, la tasa de aprendizaje y la tasa de regularización, mientras que N-BEATS fue más estable. TSFEDL se mantiene en un punto intermedio, combinando buena generalización con una moderada sensibilidad de ajuste.

Durante la preparación de los datos, la detección y tratamiento de *outliers* tuvo un impacto directo en la estabilidad del entrenamiento. Además, se comprobó que aumentar el batch size suaviza el proceso de aprendizaje, favoreciendo una convergencia más estable y reduciendo la variabilidad entre épocas.

4.2.1.6.8 Conclusiones de la evaluación

Los resultados muestran que las arquitecturas de *deep learning* ofrecen un rendimiento claramente superior a los modelos *baseline*, sobre todo en la precisión direccional y en el ratio de Sharpe simulado, dos indicadores clave en la predicción financiera. Estas arquitecturas consiguen capturar relaciones no lineales y dependencias temporales complejas, lo que se traduce en predicciones más coherentes y útiles.

Entre los modelos evaluados, N-BEATS destaca como el más completo, combinando buena precisión, consistencia y eficiencia en la identificación de los movimientos del mercado, con una mayor estabilidad que el resto, pero con un mayor coste computacional, sobre todo en tiempo de predicción.

En conjunto, los resultados confirman que las redes neuronales profundas son herramientas eficaces y valiosas para la predicción de series financieras, aunque estimar con exactitud la magnitud de los retornos sigue representando un desafío, propio de la naturaleza cambiante y caótica de los mercados financieros.

4.3 Recursos requeridos

Para el desarrollo del proyecto se ha hecho uso de los siguientes recursos:

- Ordenador de sobremesa Intel, CPU Intel Core i9 (3.6Ghz), 32Gb RAM, Disco 4TB, GPU NVIDIA GeForce RTX 2060 6GB
- Sistema Operativo Windows 11 Pro
- Software utilizado:
 - Visual Studio Code
 - Python scripts y Jupyter notebooks
 - Librerías utilizadas (pandas, numpy, scikit-learn, TensorFlow, keras, matplotlib, neuralforecast, seaborn, statsmodels, ruptures tabulate)
 - Git
 - Mendeley Reference Manager
- Datos: suscripción durante dos meses a Polygon.io, para la obtención de los datos de los cinco stocks.

La Tabla 27 muestra el coste de los recursos requeridos.

Tabla 27. Precio de los recursos requeridos. Elaboración propia.

Concepto	Importe	Comentarios
Ordenador de sobremesa	1900 €	Intel, CPU Intel Core i9, 3.6Ghz, 32Gb RAM, Disco 4TB, GPU Nvidia GeForce RTX 2060 6GB
Windows 11 Pro	250 €	
Datos	50 €	Suscripción a Polygn.io

4.4 Presupuesto

La Tabla 28 muestra el presupuesto para la realización de este trabajo.

Tabla 28. Presupuesto. Elaboración propia.

Tipo de coste	Valor	Comentarios
Horas de trabajo en el proyecto	3750 €	150 horas de trabajo valoradas a 25 €/h (valor estimado)
Equipo técnico utilizado	1900 €	Ordenador de sobremesa
Software utilizado	250 €	Windows 11 Pro
Datos	50 €	Suscripción a Polygn.io

Materiales empleados	0 €	
Total	5950 €	

4.5 Viabilidad

Este proyecto resulta plenamente viable gracias a varios factores. En primer lugar, cuenta con datos históricos fiables cotizaciones con la resolución necesaria para entrenar y evaluar los modelos. Además, el uso de Python y librerías abiertas como TensorFlow, PyTorch o Pandas facilita la implementación y experimentación, apoyándose en herramientas ampliamente utilizadas por la comunidad científica.

El diseño modular del sistema permite incorporar fácilmente nuevas arquitecturas o activos sin alterar la estructura principal, favoreciendo la comparación entre modelos. Finalmente, el calendario de trabajo establecido es realista y garantiza el tiempo necesario para cada fase. En conjunto, estos factores aseguran la viabilidad técnica y operativa del proyecto.

4.6 Resultados del proyecto

El proyecto ha dado como resultado el desarrollo de un sistema completo de predicción de precios financieros basado en técnicas de *deep learning*, capaz de procesar, modelar y evaluar series temporales de alta frecuencia.

Para ello, se construyó un ETF sintético a partir de cinco acciones tecnológicas reales, combinadas a nivel horario.

Este activo permitió disponer de un conjunto de datos coherente y representativo sobre el que aplicar los modelos predictivos.

El proceso incluyó un pipeline automatizado de preprocesamiento, con limpieza, normalización, detección de *outliers* y cálculo de retornos logarítmicos.

Sobre esta base se entrenaron tres arquitecturas de *deep learning*: una red LSTM, un modelo N-BEATS y un modelo híbrido TSFEDL.

El sistema incorpora rutinas para el cálculo automático de métricas estadísticas (MSE, RMSE, MAE, R^2), direccionales y financieras (Sharpe ratio), así como la generación de gráficos y comparativas visuales.

Todo el entorno se diseñó para ser reproducible y extensible, facilitando la incorporación de nuevos activos o intervalos temporales.

A nivel metodológico, el trabajo ha validado la metodología CRISP-DM en el contexto de predicción financiera, permitiendo integrar de forma ordenada las fases de análisis, modelado y evaluación.

También se identificaron los factores que más afectan al rendimiento de los modelos, como el tamaño del lote, la tasa de aprendizaje o la sensibilidad a los hiperparámetros.

Los resultados confirman que los modelos de *deep learning* superan claramente a los modelos base, tanto en precisión direccional como en rendimiento financiero.

Entre ellos, el modelo N-BEATS se consolidó como el más competitivo, al ofrecer el mejor equilibrio entre precisión y estabilidad, mientras que TSFEDL destacó por su comportamiento regular y LSTM por su capacidad de generalización.

En conjunto, el proyecto demuestra la viabilidad real de aplicar redes neuronales profundas a la predicción de cotizaciones de activos financieros, y establece una base metodológica sólida y replicable para futuros sistemas de trading algorítmico basados en inteligencia artificial.

Capítulo 5. DISCUSIÓN

Los resultados del proyecto confirman que las redes neuronales profundas son una herramienta eficaz para la predicción de retornos logarítmicos en activos financieros.

A pesar de la complejidad y el ruido de los mercados, los modelos desarrollados fueron capaces de identificar patrones temporales útiles y generar predicciones coherentes con la evolución real de los precios.

En comparación con los modelos base, las arquitecturas de *deep learning* lograron una mejor precisión direccional y un mayor rendimiento financiero, demostrando su capacidad para capturar relaciones no lineales y dependencias temporales que los métodos tradicionales no pueden modelar.

El uso de un ETF sintético horario, formado por cinco acciones tecnológicas, permitió disponer de un conjunto de datos diversificado y equilibrado, mejorando la estabilidad del entrenamiento y la representatividad del modelo.

En conjunto, los resultados demuestran que este tipo de modelos puede integrarse en sistemas de trading algorítmico como base para la toma de decisiones predictiva. Más allá de las métricas, el principal logro del proyecto radica en haber construido un marco metodológico sólido y reproducible, aplicable a futuras investigaciones en predicción financiera mediante inteligencia artificial.

Capítulo 6. CONCLUSIONES

6.1 Conclusiones del trabajo

Este trabajo desarrolló un sistema de predicción de precios financieros basado en técnicas de aprendizaje profundo, aplicado a un ETF sintético compuesto por cinco acciones tecnológicas representativas del mercado estadounidense.

El uso de la metodología CRISP-DM ha sido clave para estructurar el trabajo de forma ordenada y garantizar la trazabilidad de cada decisión, desde la comprensión del problema hasta la evaluación de los resultados.

Los resultados muestran que las tres arquitecturas lograron capturar parte de la dinámica del mercado, reproduciendo con coherencia la dirección general de los movimientos de precio. Entre ellas, N-BEATS destacó por su mayor precisión direccional y su mejor ratio de Sharpe, reflejando una mayor consistencia en la generación de señales predictivas. El modelo LSTM ofreció un rendimiento equilibrado y estable, mientras que TSFEDL representó con fidelidad la tendencia acumulada, aunque con menor sensibilidad ante cambios bruscos.

A pesar de los buenos resultados, la predicción exacta de la magnitud de los retornos sigue siendo un reto, condicionado por la alta volatilidad y el carácter estocástico de los mercados financieros. Aun así, los modelos desarrollados demuestran que, con un tratamiento de datos riguroso y una arquitectura bien ajustada, es posible mejorar la coherencia y la utilidad práctica de las predicciones direccionales.

En conjunto, este estudio demuestra que aplicar la inteligencia artificial a la predicción de precios financieros no solo es viable, sino también una vía muy prometedora, siempre que se combine rigor metodológico, validación empírica y una comprensión profunda del contexto económico y financiero.

6.2 Conclusiones personales

La realización de este trabajo me ha permitido profundizar tanto en el mundo del *deep learning* como en el de las finanzas.

He aprendido a entender mejor cómo se comportan los mercados financieros y, al mismo tiempo, cómo los modelos de inteligencia artificial pueden adaptarse para capturar su complejidad y naturaleza cambiante.

Uno de los mayores aprendizajes ha sido aprender a diseñar experimentos de manera metodológica, siguiendo una metodología clara y asegurando que cada resultado sea reproducible y verificable.

Esto me ha ayudado a aprender a abordar los proyectos con una mentalidad más estructurada, a valorar la importancia del proceso tanto como del resultado, y a desarrollar una forma de trabajo más rigurosa y ordenada.

También he aprendido a mirar los problemas desde un punto de vista más global, considerando no solo la arquitectura del modelo, sino todo el sistema que lo rodea: la calidad de los datos, la forma de evaluarlos y la interpretación de los resultados. En ese sentido, he comprendido que el éxito de un modelo no depende únicamente de escoger una red “adecuada”, sino también de una selección cuidadosa de los hiperparámetros, que pueden marcar la diferencia entre un experimento mediocre y uno sólido.

En definitiva, este proyecto ha sido una experiencia formativa y transformadora, que me ha permitido crecer como profesional y apasionado de la inteligencia artificial.

Capítulo 7. FUTURAS LÍNEAS DE TRABAJO

A partir de este estudio se abren varias líneas de trabajo interesantes que podrían ampliar y profundizar los resultados obtenidos.

Una primera línea sería utilizar datos reales de mercado en lugar del ETF sintético, con el fin de analizar cómo se comportan los modelos ante activos de distintos sectores (como salud o energía) y comprobar si las conclusiones se mantienen en entornos reales de negociación.

También resultaría valioso incorporar análisis de sentimiento a partir de noticias financieras o redes sociales, para complementar la información numérica con señales que reflejen el estado del mercado y las expectativas de los inversores.

Otra posibilidad sería experimentar con diferentes resoluciones temporales, como datos diarios o semanales, lo que permitiría estudiar tendencias de medio y largo plazo y evaluar el rendimiento de los modelos fuera del contexto de alta frecuencia.

Asimismo, se plantea explorar arquitecturas híbridas más avanzadas, combinando modelos basados en *Transformers* (Informer, Temporal Fusion Transformer o TimesNet) con redes recurrentes o convolucionales, para mejorar la detección de dependencias temporales y patrones no lineales.

Por último, un paso natural sería integrar estos modelos en un sistema de *trading* algorítmico real, conectado a flujos de datos en tiempo real y capaz de ejecutar estrategias basadas en sus señales. Esto permitiría evaluar su rendimiento en condiciones reales de mercado y medir su verdadero valor práctico.

Capítulo 8. REFERENCIAS

- [1] A. Koshiyama, S. Flennerhag, S. B. Blumberg, N. Firoozye, and P. Treleaven, “QuantNet: Transferring Learning Across Systematic Trading Strategies,” Jun. 2020, [Online]. Available: <http://arxiv.org/abs/2004.03445>
- [2] J. Y. Campbell, A. W. Lo, and A. C. MacKinlay, *The econometrics of financial markets*. Princeton University Press, NJ, USA, 1997.
- [3] G. E. P. Box, G. M. Jenkins, and G. C. Reinsel, *Time Series Analysis: Forecasting and Control*. San Francisco, CA, USA: Holden-Day, 1976.
- [4] M. Epaphra, “Modeling Exchange Rate Volatility: Application of the GARCH and EGARCH Models,” *Journal of Mathematical Finance*, vol. 07, no. 01, pp. 121–143, 2017, doi: 10.4236/jmf.2017.71007.
- [5] G. T. Wilson, “Time Series Analysis: Forecasting and Control, 5th Edition, by George E. P. Box, Gwilym M. Jenkins, Gregory C. Reinsel and Greta M. Ljung, 2015. Published by John Wiley and Sons Inc., Hoboken, New Jersey, pp. 712. ISBN: 978-1-118-67502-1,” *J Time Ser Anal*, vol. 37, no. 5, pp. 709–711, Sep. 2016, doi: 10.1111/jtsa.12194.
- [6] N. Tripathy, “Stock Price Prediction Using Support Vector Machine Approach,” Nov. 2019. doi: 10.33422/conferenceme.2019.11.641.
- [7] J. Zheng, D. Xin, Q. Cheng, M. Tian, and L. Yang, “The Random Forest Model for Analyzing and Forecasting the US Stock Market in the Context of Smart Finance,” 2024. doi: <https://doi.org/10.48550/arXiv.2402.17194>.
- [8] R. M. Nabi, S. Ab. M. Saeed, and H. Harron, “A Novel Approach for Stock Price Prediction Using Gradient Boosting Machine with Feature Engineering (GBM-wFE),” *Kurdistan Journal of Applied Research*, vol. 5, no. 1, pp. 28–48, Apr. 2020, doi: 10.24017/science.2020.1.3.
- [9] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, California, USA: ACM, 2016, pp. 785–794. doi: 10.1145/2939672.2939785.
- [10] G. Ke *et al.*, “LightGBM: A Highly Efficient Gradient Boosting Decision Tree,” in *Long Beach, California, USA*, Curran Associates, Inc., Dec. 2017, pp. 3149–3157. Accessed: Aug. 01, 2025. [Online]. Available: <https://proceedings.neurips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html>
- [11] J. H. Friedman, “Greedy Function Approximation: A Gradient Boosting Machine,” in *The Annals of Statistics*, vol. 29, no. 5, 2001, pp. 1189–1232.
- [12] S. Lundberg and S.-I. Lee, “A Unified Approach to Interpreting Model Predictions,” Nov. 2017, [Online]. Available: <http://arxiv.org/abs/1705.07874>

- [13] W. Chen, W. Hussain, F. Cauteruccio, and X. Zhang, "Deep Learning for Financial Time Series Prediction: A State-of-the-Art Review of Standalone and Hybrid Models," *Computer Modeling in Engineering and Sciences*, vol. 139, no. 1, pp. 187–224, 2023, doi: 10.32604/cmescs.2023.031388.
- [14] J. Kim, H. Kim, H. G. Kim, D. Lee, and S. Yoon, "A comprehensive survey of deep learning for time series forecasting: architectural diversity and open challenges," *Artif Intell Rev*, vol. 58, no. 7, Jul. 2025, doi: 10.1007/s10462-025-11223-9.
- [15] Y. Zhu, "Stock price prediction using the RNN model," in *Journal of Physics: Conference Series*, IOP Publishing Ltd, Oct. 2020. doi: 10.1088/1742-6596/1650/3/032103.
- [16] A. Moghar and M. Hamiche, "Stock Market Prediction Using LSTM Recurrent Neural Network," in *Procedia Computer Science*, Elsevier B.V., 2020, pp. 1168–1173. doi: 10.1016/j.procs.2020.03.049.
- [17] J. Chung, C. Gulcehre, K. Cho, and Y. Bengio, "Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling," Dec. 2014, [Online]. Available: <http://arxiv.org/abs/1412.3555>
- [18] A. Vaswani *et al.*, "Attention Is All You Need," Jun. 2017, [Online]. Available: <http://arxiv.org/abs/1706.03762>
- [19] H. Zhou *et al.*, "Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting," Dec. 2020, [Online]. Available: <http://arxiv.org/abs/2012.07436>
- [20] H. Wu, J. Xu, J. Wang, and M. Long, "Autoformer: Decomposition Transformers with Auto-Correlation for Long-Term Series Forecasting," Jun. 2021, [Online]. Available: <http://arxiv.org/abs/2106.13008>
- [21] B. Lim, S. O. Arik, N. Loeff, and T. Pfister, "Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting," Dec. 2019, [Online]. Available: <http://arxiv.org/abs/1912.09363>
- [22] B. N. Oreshkin, D. Carpo, N. Chapados, and Y. Bengio, "N-BEATS: Neural basis expansion analysis for interpretable time series forecasting," Feb. 2020, [Online]. Available: <http://arxiv.org/abs/1905.10437>
- [23] M. T. Ribeiro, S. Singh, and C. Guestrin, "'Why should i trust you?' Explaining the predictions of any classifier," in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, Association for Computing Machinery, Aug. 2016, pp. 1135–1144. doi: 10.1145/2939672.2939778.
- [24] D. S. Stempie'n and R. S. R. Robert'slepaczuk, "Hybrid Models for Financial Forecasting: Combining Econometric, Machine Learning, and Deep Learning Models," *Financ Res Lett*, May 2025, doi: 10.48550/arXiv.2505.19617.
- [25] C. F. Tsai and Y. C. Hsiao, "Combining multiple feature selection methods for stock prediction: Union, intersection, and multi-intersection approaches," *Decis Support Syst*, vol. 50, no. 1, pp. 258–269, Dec. 2010, doi: 10.1016/j.dss.2010.08.028.

- [26] A. R. Ondieki, G. O. Okeyo, and A. Kibe, "Stock Price Prediction Using Neural Network Models Based on Tweets Sentiment Scores," *Journal of Computer Sciences and Applications*, vol. 5, no. 2, pp. 64–75, 2017, doi: 10.12691/jcsa-5-2-3.
- [27] Ncr and J. Clinton, *Step-by-step data mining guide*. Auburn Hills, MI, USA: DaimlerChrysler, 2000.
- [28] M. Delos, "Equity price forecasting through artificial intelligence," Oct. 2025. [Online]. Available: <https://github.com/marcdp/master-ia-tfm>
- [29] C. Coronello *et al.*, "Sector Identification in a Set of Stock Return Time Series Traded at the London Stock Exchange," *Acta Physica Polonica B*, vol. 36, no. 9, pp. 2653–2679, Sep. 2005, [Online]. Available: <https://www.researchgate.net/publication/1844930>
- [30] K. Montevirgen, "Investing in tech sector stocks: A beginner's guide," Encyclopedia Britannica. Accessed: Oct. 12, 2025. [Online]. Available: <https://www.britannica.com/money/information-technology-stocks>
- [31] E. R. Mersal, K. M. Karaoğlu, and H. Kutucu, "Enhancing market trend prediction using convolutional neural networks on Japanese candlestick patterns," *PeerJ Comput Sci*, vol. 11, p. e2719, Feb. 2025, doi: 10.7717/peerj-cs.2719.
- [32] "Polygon REST Api Documentation." Accessed: Sep. 01, 2025. [Online]. Available: <https://polygon.io/docs/rest/quickstart>
- [33] "Federal Reserve Bank of St. Louis, 'SOFR - Secured Overnight Financing Rate.'" Accessed: Sep. 01, 2025. [Online]. Available: <https://fred.stlouisfed.org/series/SOFR>
- [34] R. S. Tsay, "Analysis of Financial Time Series, Third Edition," Aug. 2010, doi: 10.1002/9780470644560.
- [35] Nixtla, "NeuralForecast: Scalable and user-friendly neural forecasting models in Python," Computer software. Accessed: Oct. 01, 2025. [Online]. Available: <https://github.com/Nixtla/neuralforecast>
- [36] I. Aguilera-Martos *et al.*, "TSFEDL: A Python Library for Time Series Spatio-Temporal Feature Extraction and Prediction using Deep Learning (with Appendices on Detailed Network Architectures and Experimental Cases of Study)," Jun. 2022, [Online]. Available: <http://arxiv.org/abs/2206.03179>
- [37] T. Y. Kim and S. B. Cho, "Predicting residential energy consumption using CNN-LSTM neural networks," *Energy*, vol. 182, pp. 72–81, Sep. 2019, doi: 10.1016/j.energy.2019.05.230.

Capítulo 9. APÉNDICES

9.1 Apéndice A. Formulas y definiciones matemáticas

9.1.1 Dollar volume aggregation

$$DV_{i,t} = Close_{i,t} \times volume_{i,t}$$

$$DV_{ETF,t} = \sum_{i=1}^N w_i DV_{i,t}$$

$$volume_{ETF,t} = \frac{DV_{ETF,t}}{Price_{ETF,t}}$$

Donde, w_i es el peso del activo i en el ETF sintético, y $Price_{ETF,t}$ es el precio sintético del ETF en el instante t .

9.1.2 Métricas de error y ajuste

Error cuadrático medio (MSE):

$$MSE = \left(\frac{1}{N}\right) \cdot \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Raíz del error cuadrático medio (RMSE):

$$RMSE = \sqrt{\left(\frac{1}{N}\right) \cdot \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

donde, N es el número total de observaciones, y_i es el valor real, y $\hat{y}_i$ es el valor predicho.

Error medio absoluto (MAE):

$$MAE = \left(\frac{1}{N}\right) \cdot \sum_{i=1}^N |y_i - \hat{y}_i|$$

donde, y_i es valor real, $\hat{y}_i$ = valor predicho, y N es el número total de observaciones

Coefficiente de determinación (R^2):

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

donde, y_i es el valor real de la variable objetivo en el instante i , $\bar{y}$ es la media de los valores reales y_i , y N es el número total de observaciones.

9.1.3 Métricas direccionales

Umbral direccional:

$$\theta^- = \min(P_{25\%}, -\delta)$$

$$\theta^+ = \max(P_{75\%}, +\delta)$$

donde $\delta = 0.0001$.

Categorización:

$$clase = \begin{cases} up, & si \hat{r}_t > \delta \\ neutral, & si -\delta \leq \hat{r}_t \leq \delta \\ down, & si \hat{r}_t < -\delta \end{cases}$$

9.1.4 Ratio de Sharpe simulado

Generación de señales de dirección:

$$s_t = \begin{cases} 1, & si \hat{r}_t > \delta \\ 0, & si -\delta \leq \hat{r}_t \leq \delta \\ -1, & si \hat{r}_t < -\delta \end{cases}$$

Retornos simulados de la estrategia:

$$R_t = r_t \cdot s_t$$

Ratio de Sharpe simulado (general):

$$s_{sim} = \frac{\overline{(R_t - r_f)}}{\sigma_{(R_t - r_f)}}$$

Ratio de Sharpe simulado (riesgo libre = 0):

$$s_{sim} = \frac{\overline{(R_t)}}{\sigma_{(R_t)}}$$

donde, r_t = log retorno real del ETF en el instante t, $\hat{r}_t$ = log retorno predicho en el instante t,

9.1.5 Métricas computacionales

Tiempo de entrenamiento:

$$T_{train} = t_{fin} - t_{ini}$$

Tiempo de predicción:

$$T_{pred} = t_{fin}^{(pred)} - t_{ini}^{(pred)}$$

9.1.6 Modelo baseline random distribution predictor

Clasificación direccional:

$$d_t \in \{-1, 0, +1\}$$

donde $d_t = 1$ representa un movimiento alcista, $d_t = 0$ un movimiento neutro y $d_t = -1$ un movimiento bajista.

Distribución empírica observada:

$$P(d_t = 1) = 0.229, P(d_t = 0) = 0.559, P(d_t = -1) = 0.211$$

Estas proporciones reflejan la frecuencia real de cada dirección en el conjunto de entrenamiento.

Generación de predicciones aleatorias:

$$\hat{y}_t = \begin{cases} +x, & \text{con probabilidad } 0.229 \\ 0, & \text{con probabilidad } 0.559 \\ -x, & \text{con probabilidad } 0.211 \end{cases}$$

donde x representa la magnitud asociada a la predicción.

Valor de la magnitud:

$$x \sim U(0, \max(|\bar{y}_{train}|))$$

Sin embargo, en este trabajo se optó por fijar $x = 1$, con el fin de centrar el modelo exclusivamente en la predicción de la **dirección** del movimiento y no en su magnitud.

9.1.7 Modelo baseline random uniform predictor

Clasificación direccional:

$$d_t \in \{-1, 0, +1\}$$

donde $d_t = 1$ representa un movimiento alcista, $d_t = 0$ un movimiento neutro y $d_t = -1$ un movimiento bajista.

Distribución uniforme de probabilidad:

$$P(d_t = 1) = P(d_t = 0) = P(d_t = -1) = \frac{1}{3}$$

Generación de predicciones aleatorias:

$$\hat{y}_t = \begin{cases} +x, & \text{con probabilidad } 1/3 \\ 0, & \text{con probabilidad } 1/3 \\ -x, & \text{con probabilidad } 1/3 \end{cases}$$

donde x representa la magnitud asociada a la predicción.

Valor de la magnitud:

$$x \sim U(0, \max(|\bar{y}_{train}|))$$

Igual que en el modelo Distribution Random el valor x se fijó en 1, ya que el modelo tiene como único propósito generar direcciones aleatorias sin intentar reflejar la magnitud de los retornos.

9.2 Apéndice B. Uso de herramientas de asistencia en la redacción

Para mejorar la calidad lingüística de este trabajo, se empleó como herramienta de apoyo el modelo de lenguaje GPT-5 de OpenAI. Su uso se limitó a la revisión gramatical, la optimización del vocabulario y la mejora del estilo de redacción, siempre bajo la supervisión y edición final del autor. Cabe destacar que todas las ideas, el contenido y las argumentaciones presentadas en esta tesis son de autoría propia.

